

**UNIVERSIDAD AUTÓNOMA DE BUCARAMANGA
FACULTAD DE INGENIERÍA
PROGRAMA DE INGENIERÍA BIOMÉDICA**

**DESARROLLO DE UN SISTEMA DE DETECCIÓN Y EVALUACIÓN DE CÁNCER
TIPO MELANOMA MEDIANTE IMÁGENES POR INTELIGENCIA ARTIFICIAL**

Presentado por:
Nicolas Eduardo Leal Bustamante
Isaias Andres Rojas Murillo

Código
U00126300
U00104754

Director
Ing. Manuel Hernando Franco Arias

Codirector
PhD. Carlos Julio Arizmendi Pereira

**Bucaramanga
2024**

DEDICATORIA

A mi amada familia, qué a lo largo de mi camino hacia la realización de este proyecto de grado sobre la detección de cáncer de melanoma, ustedes han sido mi mayor fuente de inspiración y apoyo inquebrantable.

A cada paso del camino, su amor, aliento y presencia han sido mi fuerza motriz, recordándome constantemente la importancia de mi labor y la razón detrás de mis esfuerzos.

A mi querida madre Blanca Rocio Bustamante Paez, padre Ruben Dario Leal Rivera y a mi único hermano Jakson Dario Leal Bustamante, su dedicación y amor incondicional han sido mi roca, guiándome en cada desafío y celebrando cada logro. Sus sacrificios y valores han forjado el camino que me ha llevado hasta aquí, y es a ustedes a quienes dedico los frutos de este trabajo.

Sin dejar atrás a Dios, fuente de sabiduría y fortaleza, agradezco por las oportunidades que me has brindado y por guiarme en esta jornada de aprendizaje. Tu luz ha iluminado mi camino y me ha dado la confianza para enfrentar los obstáculos con valentía.

Este proyecto es una representación humilde de mi gratitud hacia cada uno de ustedes. Que estas palabras sirvan como un recordatorio eterno de cuánto significan para mí y de cómo su amor y aliento son el cimiento sobre el cual construyo mi futuro.

Nicolás Eduardo Leal Bustamante

DEDICATORIA

Somos lo que observamos, y este trabajo de grado quiero consagrarlo a lo que he observado y aprendido durante la vida de mis padres.

Su sacrificio siempre me ha empujado a ser un guerrero. Sus largas horas de trabajo duro y horas dedicadas en las madrugadas a la oración y a la labor, me motiva a dar siempre lo mejor, pasando por encima de la mediocridad que existe en la juventud.

Gracias por construir un buen ciudadano útil para servir y anhelo llevar siempre su legado en Mentalidad y principios cristianos.

A mi hermano, por ser ese ejemplo de admiración y berraquera. Dios te de mucha vida para lograr tus anhelos más profundos.

Isaías Andrés Rojas Murillo

AGRADECIMIENTOS

Queremos expresar el más sincero agradecimiento a todas las personas que han contribuido de manera invaluable a la realización de este proyecto sobre la detección de cáncer de melanoma.

En primer lugar, a nuestras familias, las cuales son una fuente constante de apoyo y amor. Agradecer por su paciencia, aliento y sacrificios que nos han permitido embarcarnos en esta jornada académica. Cada uno de ustedes ha sido el pilar fundamental, y este trabajo es un testimonio de su influencia positiva en mi vida.

Agradezco profundamente a nuestro profesor de tesis, Ingeniero Manuel Hernando Franco Arias, por su guía experta, sabiduría y dedicación en la orientación a lo largo de este proyecto. Sus conocimientos y consejos han sido esenciales para dar forma a esta investigación.

La gratitud se extiende a los amigos y compañeros de clase, quienes han compartido sus ideas, discusiones y momentos inolvidables durante este viaje educativo. Sus aportes y colaboración han enriquecido enormemente mi experiencia.

Finalmente, se agradece a todas las personas cuyas historias y experiencias relacionadas con el proyecto han iluminado nuestra comprensión y determinación para contribuir a la detección temprana y el tratamiento efectivo de esta enfermedad. Su valentía y lucha continúan inspirándome. Cada uno de ustedes ha sido un eslabón vital en esta cadena de gratitud, y este proyecto es un tributo a sus

contribuciones. Que este trabajo sea un recordatorio duradero de mi agradecimiento sincero.

Isaias Andres Rojas Murillo, Nicolas Eduardo Leal Bustamante

RESUMEN

Este proyecto se centra en la creación de un sistema de detección médica basado en aprendizaje profundo (*deep learning*). El objetivo principal es desarrollar un sistema que procese imágenes dermatoscópicas para identificar la presencia de melanoma, sin determinar la etapa del cáncer.

Para abordar la necesidad de herramientas efectivas en la detección temprana del melanoma, se utilizaron algoritmos de inteligencia artificial y una base de datos balanceada con 4000 imágenes dermatoscópicas. Se emplearon tres tipos de optimizadores de deep learning para mejorar y ajustar la exactitud de los modelos, optimizando la tasa de aprendizaje al ajustar los parámetros internos de la red.

El proyecto comparó la técnica de creación de la estructura desde cero (*from scratch*) con el *transfer learning*, seleccionando el mejor modelo según las métricas de rendimiento.

La principal contribución del sistema es su capacidad para discriminar entre lesiones benignas y malignas, ofreciendo un apoyo adicional a los profesionales de la salud en la toma de decisiones. Los resultados obtenidos hasta ahora demuestran un alto grado de sensibilidad y puntuación F1, en la detección de melanomas a partir de imágenes dermatoscópicas, indicando un potencial significativo para mejorar el diagnóstico temprano y preciso de este tipo de cáncer de piel.

En resumen, este proyecto representa un avance significativo en la detección de cáncer de piel mediante deep learning y redes neuronales convolucionales,

ofreciendo una herramienta prometedora que complementa el diagnóstico médico convencional.

Palabras claves: *Inteligencia Artificial, Cáncer De Piel, Melanoma, Deep Learning, Procesamiento De Imágenes, Transfer learning, Redes neuronales convolucionales, tasa de aprendizaje, batch size, Optimizador*

ABSTRACT

The project's aim is focused on the creation of a medical detection system based on deep learning. The main objective is to develop a system that processes dermoscopic images to identify the presence of melanoma, without determining the stage of the cancer.

To address the need for effective tools in the early detection of melanoma, artificial intelligence algorithms and a balanced database with 4000 dermoscopic images were used. Three types of deep learning optimizers were used to improve and tune the accuracy of the models, optimizing the learning rate by adjusting the internal parameters of the network.

The project compared the technique of creating the structure from scratch with transfer learning, selecting the best model according to performance metrics.

The main contribution of the system is its ability to discriminate between benign and malignant lesions, offering additional support to health professionals in decision making. The results obtained so far demonstrate a high degree of sensitivity and F1 score in the detection of melanomas from dermoscopic images, indicating significant potential to improve the early and accurate diagnosis of this type of skin cancer.

In summary, this project represents a significant advance in the detection of skin cancer through deep learning and convolutional neural networks, offering a promising tool that complements conventional medical diagnosis.

Keywords: Artificial Intelligence, Skin Cancer, Melanoma, Deep Learning, Image Processing, Transfer learning, Convolutional neural networks, learning rate, batch size, Optimizer algorithm

TABLA DE CONTENIDO

Capítulo I.....	17
1 Problema de investigación.....	17
1.1 Introducción.....	17
1.2 Descripción del Problema.....	18
1.3 Justificación.....	19
1.4 Pregunta de investigación.....	21
1.5 Objetivo General.....	22
1.6 Objetivos Específicos.....	22
1.7 Limitaciones y Delimitaciones.....	22
Capítulo II.....	24
2 Marco teórico y Estado del Arte.....	24
2.1 Estado Del Arte.....	24
2.2 Marco Legal.....	27
2.3 Marco Teórico.....	28
2.3.1 ¿Qué es lunar?.....	28
2.3.2 ¿Qué es el melanoma?.....	29
2.3.3 Métodos de detección de melanoma.....	30
2.3.4 Inteligencia Artificial.....	31
2.3.5 Redes Neuronales Artificiales.....	32
2.3.6 Redes Neuronales Artificiales Convolucionales.....	33
2.3.7 <i>Deep Learning y transfer learning</i>	33

Capítulo III.....	35
3 Metodología.....	35
3.1 Base de datos.....	36
3.2 Investigación de técnicas de inteligencia artificial.....	36
3.3 Procesamiento de imágenes.....	37
3.4 Código y selección de software.....	37
3.5 Selección del diseño de interfaz.....	38
3.6 Pruebas de funcionamiento.....	38
Capítulo IV.....	39
4 Resultados y análisis de resultados.....	39
4.1 Selección del software de programación.....	39
4.2 Creación del modelo desde el cero (from scratch - Students net).....	40
4.2.1 Optimizadores y tasa de aprendizaje.....	40
4.2.2 Optimizador RMSprop.....	40
4.2.3 Optimizador Sgmd.....	45
4.2.4 Optimizador Adam.....	48
4.2.5 Análisis de selección del modelo creado.....	51
4.3 Creación del modelo con transfer learning.....	55
4.3.1 Análisis de los campeones - transfer learning.....	74
4.3.2 Tablas resumen - transfer learning.....	75
4.4 Creación del Modelo desde cero - from scratch Python.....	81
4.5 Interfaz.....	84
4.5.1 Menú de usuario.....	88
4.5.2 Explicación de las partes de la interfaz.....	89
Capítulo V.....	91

5.1 Discusiones.....	91
5.2 Conclusiones y recomendaciones.....	95
5.2 Referencias.....	98
5.3 Anexos.....	101

LISTA DE FIGURAS

Figura 1 Base del proyecto Yifan Yang	25
Figura 2 Red neuronal artificial.....	27
Figura 3 Lunar o nevus melanocítico.....	29
Figura 4 Melanomas malignos.....	30
Figura 5 Metodo de detección de melanomas “ABCDE”.....	31
Figura 6 Esquema metodológico.....	35
Figura 7 1er optimizador RMSprop con un porcentaje de 75.83 %.....	42
Figura 8 1er optimizador RMSprop con un porcentaje de 79.17 %.....	42
Figura 9 1er optimizador RMSprop con un porcentaje de 80.62 %.....	43
Figura 10 1er optimizador RMSprop con un porcentaje de 81.88 %.....	45
Figura 11 2do optimizador SGMD con un porcentaje de 78.54 %.....	46
Figura 12 2do optimizador SGMD con un porcentaje de 77.08 %.....	47
Figura 13 3er optimizador Adam con un porcentaje de 77.08 %.....	48
Figura 14 3er optimizador Adam con un porcentaje de 79.58 %.....	49
Figura 15 3er optimizador Adam con un porcentaje de 80.00 %.....	50
Figura 16 3er optimizador Adam con un porcentaje de 81.04 %.....	51
Figura 17 Estructura de Students Net.....	53

Figura 18 Gráfica porcentaje vs tasa de aprendizaje de la red Alexnet optimizador Rmsprop(32 <i>Batch size</i>).....	57
Figura 19 Gráfica porcentaje vs tasa de aprendizaje de la red Alexnet optimizador Rmsprop(64 <i>Batch size</i>).....	58
Figura 20 Gráfica porcentaje vs tasa de aprendizaje de la red Alexnet optimizador Adam (32 <i>Batch size</i>).....	59
Figura 21 Gráfica porcentaje vs tasa de aprendizaje de la red Alexnet optimizador Adam (64 <i>Batch size</i>).....	59
Figura 22 Gráfica porcentaje vs tasa de aprendizaje de la red Alexnet optimizador Sgdm (32 <i>Batch size</i>).....	61
Figura 23 Gráfica porcentaje vs tasa de aprendizaje de la red Alexnet optimizador Sgdm (64 <i>Batch size</i>).....	61
Figura 24 Gráfica porcentaje vs tasa de aprendizaje de la red Resnet 50 optimizador Rmsprop(32 <i>Batch size</i>).....	62
Figura 25 Gráfica porcentaje vs tasa de aprendizaje de la red Resnet 50 optimizador Rmsprop(64 <i>Batch size</i>).....	62
Figura 26 Gráfica porcentaje vs tasa de aprendizaje de la red Resnet 50 optimizador Adam(32 <i>Batch size</i>).....	64
Figura 27 Gráfica porcentaje vs tasa de aprendizaje de la red Resnet 50 optimizador Adam(64 <i>Batch size</i>).....	64
Figura 28 Gráfica porcentaje vs tasa de aprendizaje de la red Resnet 50 optimizador Sgdm(32 <i>Batch size</i>).....	65
Figura 29 Gráfica porcentaje vs tasa de aprendizaje de la red Resnet 50 optimizador Sgdm(64 <i>Batch size</i>).....	65

Figura 30 Gráfica porcentaje vs tasa de aprendizaje de la red Vgg 16 optimizador Rmsprop(32 <i>Batch size</i>).....	67
Figura 31 Gráfica porcentaje vs tasa de aprendizaje de la red Vgg 16 optimizador Rmsprop(64 <i>Batch size</i>).....	67
Figura 32 Gráfica porcentaje vs tasa de aprendizaje de la red Vgg 16 optimizador Adam(32 <i>Batch size</i>).....	68
Figura 33 Gráfica porcentaje vs tasa de aprendizaje de la red Vgg 16 optimizador Adam(64 <i>Batch size</i>).....	69
Figura 34 Gráfica porcentaje vs tasa de aprendizaje de la red Vgg 16 optimizador Sgdm(32 <i>Batch size</i>).....	70
Figura 35 Gráfica porcentaje vs tasa de aprendizaje de la red Vgg 16 optimizador Sgdm(64 <i>Batch size</i>).....	70
Figura 36 Gráfico comparativo de los mejores valores de clasificación para las 3 redes pre entrenadas por cada optimizador(32 <i>Batch size</i>).....	71
Figura 37 Gráfico comparativo de los mejores valores de clasificación para las 3 redes pre entrenadas por cada optimizador(64 <i>Batch size</i>).....	73
Figura 38 Ejemplo de matriz de confusión.....	74
Figura 39 Interfaz gráfica ventana 1.....	84
Figura 40 Interfaz gráfica ventana 2 (parte 1).....	85
Figura 41 Interfaz gráfica ventana 2 (parte 2).....	86
Figura 42 Interfaz gráfica ventana 2 (parte 3).....	87
Figura 43 Interfaz gráfica ventana 2 (parte 4).....	88
Figura 44 Partes de la interfaz gráfica	89

LISTA DE TABLAS

Tabla 1 Matriz de selección del algoritmo con escala de 1 a 3.....	40
Tabla 2 1er Resultado del Optimizador RMSprop.....	42
Tabla 3 2do Resultado del Optimizador RMSprop.....	43
Tabla 4 3er Resultado del Optimizador RMSprop.....	44
Tabla 5 4to Resultado del Optimizador RMSprop.....	45
Tabla 6 1er Resultado del Optimizador SGMD.....	47
Tabla 7 2do Resultado del Optimizador SGMD.....	47
Tabla 8 1er Resultado del Optimizador Adam.....	48
Tabla 9 2do Resultado del Optimizador Adam.....	49
Tabla 10 3ro Resultado del Optimizador Adam.....	50
Tabla 11 4to Resultado del Optimizador Adam.....	51
Tabla 12 Comparativa de todos los porcentajes arrojados por los 3 optimizadores.	52
Tabla 13 Medidas de bondad de Students Net.....	53
Tabla 14 Porcentajes de Accuracy para training, validation y test para Alexnet con el optimizador rmsprop.....	57
Tabla 15 Porcentajes de Accuracy para training, validation y test para Alexnet con el optimizador Adam.....	58
Tabla 16 Porcentajes de Accuracy para training, validation y test para Alexnet con el optimizador sgdm.....	60
Tabla 17 Porcentajes de Accuracy para training, validation y test para Resnet 50 con el optimizador rmsprop.....	62
Tabla 18 Porcentajes de Accuracy para training, validation y test para Resnet 50 con el optimizador Adam.....	63

Tabla 19 Porcentajes de Accuracy para training, validation y test para Resnet 50 con el optimizador sgdm.....	65
Tabla 20 Porcentajes de Accuracy para training, validation y test para Vgg 16 con el optimizador rmsprop.....	66
Tabla 21 Porcentajes de Accuracy para training, validation y test para Vgg 16 con el optimizador Adam.....	68
Tabla 22 Porcentajes de Accuracy para training, validation y test para Vgg 16 con el optimizador sgdm.....	70
Tabla 23 Tabla comparativa de los valores más altos arrojados por Alexnet, Restnet50 y Vgg 16 (<i>batch size</i> 32).....	71
Tabla 24 Tabla comparativa de los valores más altos arrojados por Alexnet, Restnet50 y Vgg 16 (<i>batch size</i> 64).....	72
Tabla 25 Tabla resumen de la Exactitud.....	77
Tabla 26 Tabla resumen de la Sensibilidad.....	78
Tabla 27 Tabla resumen de la Precisión.....	79
Tabla 28 Tabla resumen de la Especificidad.....	80
Tabla 29 Tabla resumen de la Puntuación F1 (F1 score).....	81
Tabla 30 Exactitud para Optimizadores de Keras Tuner.....	82
Tabla 31 Sensibilidad para Optimizadores de Keras Tuner.....	83
Tabla 32 Precisión para Optimizadores de Keras Tuner.....	83
Tabla 33 Especificidad para Optimizadores de Keras Tuner.....	83
Tabla 34 Puntuación F1 para Optimizadores de Keras Tuner.....	84
Tabla 35 Comparación de los mejores modelos.....	95

CAPÍTULO I

1. PROBLEMA DE INVESTIGACIÓN

1.1 INTRODUCCIÓN

El cáncer de piel, particularmente el melanoma, representa un desafío significativo en el campo de la salud, siendo uno de los cánceres más agresivos y potencialmente letales. A medida que las tasas de incidencia han ido en aumento en los últimos años, la detección temprana de este tipo de cáncer se ha vuelto fundamental para mejorar las tasas de supervivencia y el pronóstico de los pacientes. El melanoma también puede manifestarse en los ojos y, rara vez, dentro del cuerpo, como en la nariz o la garganta.

La causa exacta de todos los melanomas no está clara, pero la exposición a la radiación ultravioleta (UV) de la luz solar o de las lámparas y de las camas solares aumenta el riesgo de tener melanoma. Limitar la exposición a la radiación UV puede ayudar a reducir el riesgo de tener melanoma.(Melanoma, 2023).

La evaluación de lesiones de la piel, especialmente en su identificación rápida, ha sido históricamente un desafío para los profesionales médicos, dado que la inspección visual a veces no es suficiente para diferenciar entre lesiones benignas y malignas. En este contexto, el uso del aprendizaje profundo se presenta como una oportunidad prometedora para detección temprana del melanoma.

El presente proyecto tiene como objetivo desarrollar un sistema basado en inteligencia artificial que permita analizar imágenes de lesiones de la piel, en este caso cáncer de piel melanoma y determinar, de manera automatizada y precisa, la probabilidad de que una lesión sea maligna o benigna. Este sistema busca ser una

herramienta complementaria para los profesionales de la salud, facilitando la detección temprana y la toma de decisiones clínicas fundamentadas.

Para lograr este propósito, se utilizará una base de datos balanceada de 4000 imágenes extraídas desde ISIC, y se realizará una comparación de técnicas de aprendizaje profundo.

El desarrollo de este sistema no solo representa un avance tecnológico significativo, sino que también tiene el potencial de impactar positivamente en la atención médica, proporcionando un método preciso y eficiente para la detección temprana del cáncer de piel tipo melanoma.

El presente documento detallará el proceso de investigación, desarrollo y validación de este sistema, junto con sus resultados e implicaciones en el campo médico.

1.2 DESCRIPCIÓN DEL PROBLEMA

Cuando se habla de cáncer, se refiere a una gran variedad de enfermedades las cuales tienen algo en común, el desarrollo de células anormales o también conocidas como malignas. Ellas se dividen, se multiplican y se esparcen sin control en cualquier parte del cuerpo humano.

El cáncer se produce cuando el ADN (Ácido desoxirribonucleico) de una célula cambia. Según el ministerio de salud, en Colombia 138 mil personas están diagnosticadas anualmente con cáncer, de esas personas, 33.100 cobran vida, teniendo en cuenta que 16.300 son hombres y 16.800 son mujeres. El cáncer lo producen diferentes factores, pueden ser mutaciones genéticas, la exposición a la radiación, fumar, etc. (Cáncer, s. f.).

Las enfermedades en la piel son mayormente causadas por radiación solar, entre ellas está el cáncer de piel tipo melanoma, donde se da más frecuentemente en personas blancas y en adultos mayores.

Los melanomas tienen 5 etapas, etapa 0 (melanoma in situ) que es cuando no han crecido en la capa de la piel, luego va desde la etapa 1 hasta la 4, entre más alta sea la etapa mayor será la propagación del cáncer. Este cáncer a comparación de otros, su expansión por el cuerpo sucede más rápido, lo que hace más fácil contaminar a otros órganos hasta causar la muerte.(Etapas del cáncer de piel tipo melanoma, s. f.)

En Colombia se diagnosticaron entre el año 2020 y 2021 alrededor de 5.900 casos nuevos, con un aumento del 30% en la tasa de mortalidad y un 16% menor en nuevos casos reportados con respecto al periodo 2019-2020. Según datos de la CAC, por cada 100 mil Colombianos hay 8.88 personas que tienen cáncer de melanoma. (Valencia, 2022)

Así mismo, a nivel nacional el año pasado se estimó que el periodo de espera para ser diagnosticado es en promedio 50 días y, para recibir tratamiento casi a los 80 días, en lugares caribeños donde la exposición solar es mayor se calculó entre los 55 y 100 días. Todo esto influye en el avance descontrolado del cáncer el cual, según la liga mundial contra el cáncer es el tipo de cáncer de piel con más incidencia en metástasis.

1.3 JUSTIFICACIÓN

Según estudios del Instituto Nacional de Cancerología de Colombia, el melanoma es el cáncer de piel *menos frecuente* con un 16.1 % de los casos reportados para

cáncer de piel. Pero es el más incidente y letal. Debido al cambio climático y la contaminación para el año 2022 según la Sociedad Americana contra el Cáncer calcula que morirán en el mundo 7.650 personas a causa de esta enfermedad (Datos | Cáncer de Piel - Liga Colombiana contra el Cáncer, s. f.). En el contexto Colombiano según la liga colombiana contra el cáncer, por cada 100 mil habitantes 4,4 hombres y 4,6 mujeres padecerán cáncer de melanoma maligno (Estadísticas importantes sobre el cáncer de piel tipo melanoma, s. f.), con una mortalidad en el 2021 del 7,5 % aproximadamente según datos del Fondo Colombiano de enfermedades de alto costo (CAC), donde en el periodo 2020 - 2021 se reportaron 5.906 casos totales con 530 casos nuevos y 441 muertes (Día mundial del melanoma 2022 | Cuenta de Alto Costo, s. f.).

Aunque los casos nuevos del periodo 2019-2020 al 2020-2021 disminuyeron en un 16%, la mortalidad aumentó un 30%. Lo que implica un reto para la salud pública colombiana, porque se tienen grandes problemas en el acceso para el diagnóstico oportuno, para una enfermedad que es rápida en hacer metástasis. La CAC estima que 11 días se demora entre la biopsia y el inicio del tratamiento. Y en promedio, pasan 49 días para ser diagnosticado y 83 para recibir tratamiento, y en las costas colombianas entre 55 y 100 días correlativamente (Día mundial del melanoma 2022 | Cuenta de Alto Costo, s. f.).

Así mismo, según datos del Departamento Administrativo Nacional de Estadísticas DANE del año 2017, para las mujeres, en la ciudad de Bucaramanga, las comunas más afectadas por melanoma y otros tipos de cáncer de piel son: la comuna nororiental, la concordia, la pedregosa, el sur y el mutis. Con unas tasas de

incidencias del 6, 6, 11, 6 y 7 por cada 100.000 habitantes respectivamente. Para los hombres, las comunas son: García Rovira, Provenza, Cabecera del llano, Oriental, Mororico y el mutis. Con una tasa de incidencia por cada 100 mil habitantes de 5, 7, 9, 9 y 16 en el orden dado.

A raíz de lo mencionado anteriormente, este proyecto busca, mediante técnicas de inteligencia artificial (IA), asistir al sistema de salud en la detección temprana del melanoma. Este desarrollo proporcionará una herramienta de IA útil para los profesionales de la salud, especialmente considerando que los tiempos de diagnóstico en Colombia son elevados, dado a que el tiempo promedio de espera para iniciar el tratamiento del melanoma y otros tumores malignos de piel está incluido en los indicadores priorizados por el Observatorio Nacional de Cáncer (ONC).

Además, el proyecto se alinea con el primer objetivo del Departamento Nacional de Planeación (DNP) bajo su lema "Salud para todos con calidad y eficiencia, sostenible por todos". Este objetivo es "Lograr la satisfacción del usuario brindándole mayor calidad y oportunidad en la atención". El proyecto pretende ofrecer a las personas que viven lejos de las grandes ciudades la posibilidad de ser diagnosticadas a tiempo mediante una simple fotografía, permitiéndoles comenzar el tratamiento adecuado de manera oportuna.

1.4 PREGUNTA DE INVESTIGACIÓN

¿Cómo detectar y evaluar si un registro fotográfico es positivo o no para cáncer de melanoma mediante el uso de procesamiento de imágenes e inteligencia artificial?

OBJETIVOS

1.5 OBJETIVO GENERAL

Desarrollar un sistema basado en inteligencia artificial para el procesamiento de imágenes que contribuya a la detección si una imagen es positiva para cáncer de piel tipo melanoma.

1.6 OBJETIVOS ESPECÍFICOS

1. Diseñar la arquitectura de un código con inteligencia artificial que permita el proceso de detección y evaluación de melanomas.
2. Diseñar interfaz de usuario para la clasificación de las imágenes que requieren saber si es cáncer de tipo melanoma aplicando la inteligencia artificial.
3. Evaluar el correcto funcionamiento del sistema mediante imágenes ya clasificadas con cáncer de piel tipo melanoma para la cuantificación de la precisión del modelo.

1.7 LIMITACIONES Y DELIMITACIONES

Aunque el sistema desarrollado es altamente preciso, es importante tener en cuenta factores externos en la toma de fotografías, como la iluminación, la calidad de la imagen y el tipo de dispositivo, ya que no todos los entornos de captura serán óptimos.

La limitación principal del sistema radica en su enfoque exclusivo en la detección de melanoma, dejando de lado otras formas de cáncer de piel y lesiones cutáneas. Además, hay restricciones relacionadas con los algoritmos de inteligencia artificial utilizados, ya que el sistema se basa en algoritmos específicos de deep learning y modelos pre entrenados.

CAPÍTULO II

2 MARCO TEÓRICO Y ESTADO DEL ARTE

2.1 ESTADO DEL ARTE

Este proyecto se enfoca en el melanoma, conocido como el tipo de cáncer de piel más peligroso. Detectarlo en su etapa 0 (*in situ*), cuando aún no ha invadido más allá de la capa superior de la piel (la epidermis), es crucial, ya que aumenta significativamente las probabilidades de recuperación. Debido a la alta mortalidad asociada a este cáncer, se han realizado numerosos estudios e investigaciones. El objetivo es desarrollar una herramienta de inteligencia artificial para detectar el melanoma, facilitando que los pacientes accedan más rápidamente a la prueba de referencia, la biopsia.

El académico Yifan Yang, de la División de Ciencias Biológicas de la Universidad de California en San Diego, EE. UU., publicó un artículo de investigación en 2021. En este artículo, concluye que la detección temprana del melanoma aumenta significativamente las probabilidades de supervivencia. Si el melanoma se detecta en la etapa IV, cuando ya se ha propagado (metástasis) a los ganglios linfáticos distantes o a otras áreas del cuerpo, la probabilidad de recuperación completa es del 39%. En cambio, si el melanoma se detecta en la etapa 0 o I, la tasa de éxito en la recuperación es del 93%. Gracias al *machine learning* pudieron clasificar la enfermedad y encontrar la etapa donde se encuentra el melanoma.(Yifan Yang, 2021). Base del proyecto, ver *figura 1*.

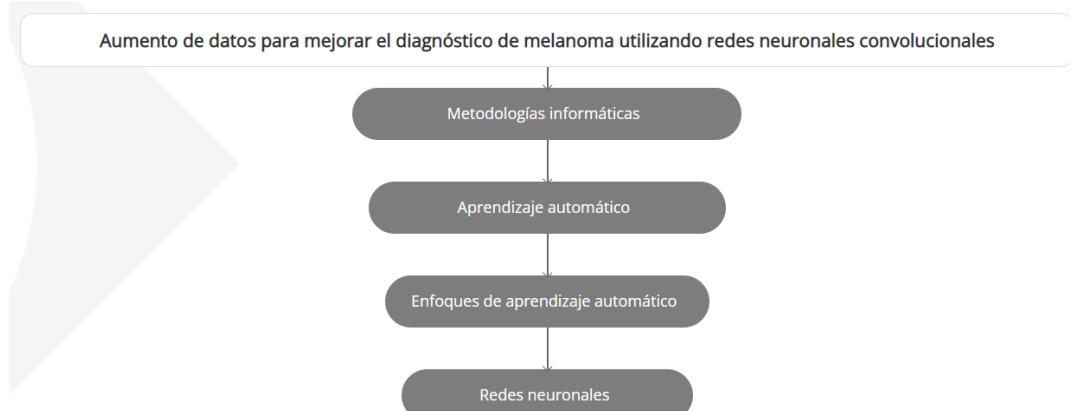


Figura 1. Base del proyecto de Yifan Yang. (Yifan Yang, 2021).

En 2021, los investigadores Yanyang Gu, Zongyuan Ge, C. Paul Bonnington y Junio Zhou publicaron un artículo en el que proponen dos métodos para la detección de enfermedades de la piel. El primer método utiliza un clasificador de imágenes basado en una red neuronal convolucional profunda (CNN) supervisada, probada en ImageNet, una extensa base de datos visual diseñada para la investigación en reconocimiento de objetos visuales. El segundo método consiste en ajustar la CNN utilizando dos conjuntos de datos específicos de enfermedades de la piel.

La segunda técnica utiliza el método de Adversarial Learning en inteligencia artificial, aplicado como adaptación de dominio. Este método traduce atributos invariantes desde el dominio original para mejorar el rendimiento en la detección de melanomas. (NCBI - WWW Error Blocked Diagnostic, s. f.)

En 2019, los investigadores Sara Laghami, Amal Tmiri, y Bouchaib Cherradi de la Facultad de Ciencias de la Universidad Chouaib Doukkali (UCD) en Jadida, Marruecos, publicaron un artículo de investigación sobre el cáncer de mama. No obstante, también abordaron el papel de las enfermedades hereditarias en los

melanomas, destacando que la probabilidad de contraer esta enfermedad aumenta si algún familiar ya la padece.

Así mismo presentan diferentes técnicas de inteligencia artificial para el aprendizaje automático como las redes neuronales y los árboles de decisión, normalmente estos son utilizados para predecir un diagnóstico sobre el cáncer, hepatitis y enfermedades cardiovasculares. Los autores hicieron análisis de mamografías de unos pacientes y detectaron distintos tipos de cáncer como malignos o benignos.

(*Machine Learning based System for Prediction of Breast Cancer Severity*, 2019)

Md. Arman Hossin; Farhan Fuad Rupom; Hasibur Rashid Mahi; Anik Sarker; Farshid Ahsan; Sandman Warech de la Facultad de Informática e Ingeniería de la Universidad BRAC en Dhaka, Bangladesh. Realizaron una investigación publicada en el 2020.

En primera instancia recalcan que el melanoma se origina cuando los melanocitos comienzan a crecer sin control alguno lo que traduce a una lesión en la piel, también resaltan el costoso tratamiento que crece junto con el avance del melanoma. Ellos desarrollaron un sistema capaz de detectar el melanoma de manera automática, mediante la examinación de una imagen.

Este sistema fue implementado con una red neuronal convolucional para que la detección tuviera mayor precisión, según las pruebas realizadas al sistema, este es capaz de detectar el cáncer de melanoma con un porcentaje de alrededor de 94% de efectividad. (*Melanoma Skin Cancer Detection Using Deep Learning and Advanced Regularizer*, 2020). Red neuronal artificial ver *figura 2*.

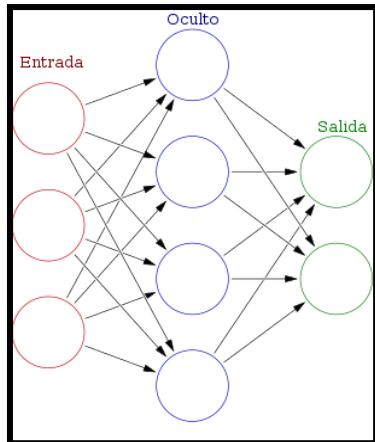


Figura 2. Red neuronal artificial.(red neuronal - Google Zoeken, s. f.)

2.2 MARCO LEGAL

En este proyecto de grado como se van a tratar con bases de datos de pacientes, se incluye el buen tratamiento de datos que se rige en la ley de protección de datos personales 1581 del 2012 "ley de habeas data" (Ley 1581 de 2012 - Gestor Normativo, 2022), la cual reconoce y protege la información recolectada, esta ley tiene como objetivo cumplir el derecho constitucional de que las personas puedan conocer, actualizar y rectificar la información recolectada sobre ellas mismas en bases de datos. Así mismo se asegura que los datos personales de los pacientes no serán revelados de ninguna manera.

Los derechos de autor permiten una protección jurídica al software, este derecho se rige bajo la Ley 23 de 1982 (Ley 23 de 1982 - Gestor Normativo, s. f.) que hablan de los derechos de autor. Esta ley regula los derechos morales y patrimoniales que la ley concede a los autores por el hecho de crear una obra literaria, artística o científica, que en este caso como en un software que se desarrolla con materia de investigación se incluye para los derechos de autor.

También el decreto 1360 de 1989 (Decreto 1360 de 1989, 2022), complementa la ley 23 y este reglamenta la inscripción del soporte lógico (software) en el Registro Nacional del Derecho de Autor. La ley 44 de 1993 , en ella se modifica y adiciona la Ley 23 de 1982 (Leyes desde 1992, LEY 0044 1993).

Finalmente está la ley 1915 del 2018, la cual dice que Colombia implementa algunas de las disposiciones del Tratado de Libre Comercio (en adelante TLC), celebrado entre Colombia y Estados Unidos, en materia de derecho de autor y derechos conexos en el entorno digital. (De la Ley 1915 de 2018 al Tratado de Libre Comercio entre Colombia y Estados Unidos, s. f.).

Si se habla de registro del software se recurre a la Dirección Nacional de Derecho del Autor de Colombia la cual deberá tener unos requisitos puntuales para el registro.

2.3 MARCO TEÓRICO

2.3.1 ¿Qué es un lunar?

Los lunares son manchas comunes que crecen sobre la piel las cuales no presentan riesgo alguno, estas pequeñas manchas tienen colores como rosado, oscuros o cafés. Su forma tiende a ser redonda u ovalada, algunos lunares tienen relieve o pueden ser lisos. Estos lunares se crean cuando las células productoras del pigmento en la piel conocidas como melanocitos, se acopian y crecen en grupos. Las personas pueden tener entre 10 y 40 lunares en todo el cuerpo. El cuerpo puede producir lunares a medida que pasan los años como también puede eliminarlos. Se cree que por cada diez personas, una puede poseer lunares atípicos,

es decir, diferente a los demás y pueden presentar enfermedades, como el cáncer de piel tipo melanoma.(“Lunares,” 2021). El lunar ver *figura 3*.



Figura 3. Lunar o nevus melanocítico. (Bagazgoitia, 2019)

2.3.2 ¿Qué es el melanoma?

El melanoma conforma solo el 1 % de los casos de cáncer de piel, pero causa la gran mayoría de las muertes por este tipo de cáncer (“Estadísticas Importantes Sobre El Cáncer de Piel Tipo Melanoma,” 2022). El melanoma se detecta cuando un lunar cambia en su tamaño, su forma, color o textura de la lesión, en su mayoría los melanomas tienden a ser de color negro o un negro azulado, aparentemente suele verse inofensivos cuando están apareciendo. Cuando un melanoma es detectado, los especialistas identifican la etapa en la que está el melanoma, hay varios tratamientos pero el más efectivo es el método de la cirugía , hay otros como la quimioterapia, radiación, terapia biológica y terapia dirigida. Melanoma malignos ver *figura 4*.

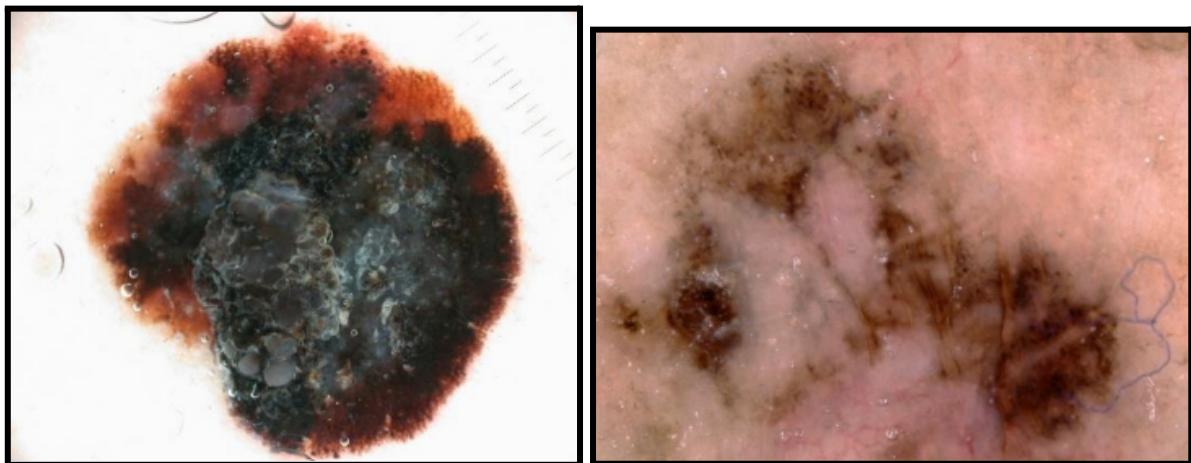


Figura 4. Melanomas malignos. (Troya-Martín, 2008)

2.3.3 Métodos de detección de melanomas

El método más conocido o mas utilizado para la detección y el diagnóstico de melanomas es el “ABCDE” el cual consiste en (“Melanoma,” 2020):

A = Asimetría: El contorno de una parte de la lesión no es igual al resto.

B = Bordes: Tiene bordes desiguales, de bajo contraste e irregulares.

C = Color: No es uniforme y puede incluir tonalidades negras, cafés y de color canela.

D = Diámetro: Cambian de tamaño y se van poniendo más grandes.

E = Evolución: Se presentan cambios en el lunar en las últimas semanas o meses.

Método de detección “ABCDE” del melanoma ver *figura 5*.

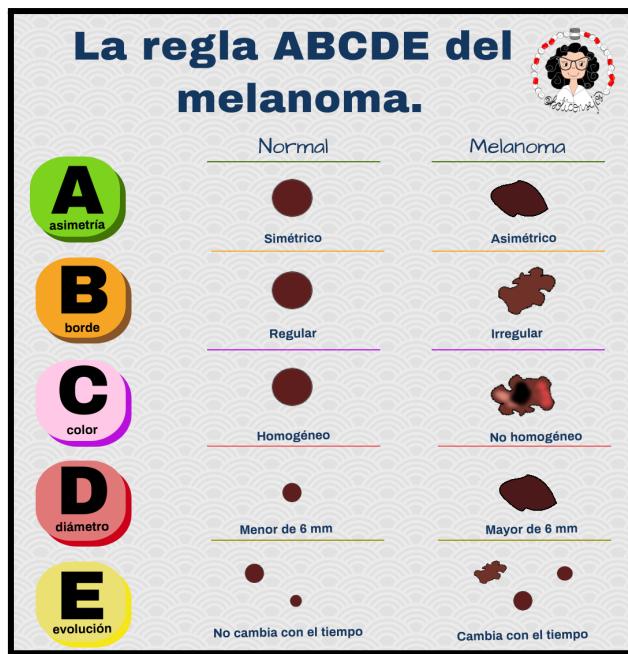


Figura 5. Método de detección de melanomas “ABCDE”. (Cáncer de piel - Melanoma síntomas, s. f.)

Otro método es la evaluación visual de los melanomas en una lista de verificación ponderada de 7 puntos conocida como “Weighted Glasgow 7-point checklist” (Jones, Ranmuthu, Hall, Funston, & Walter, 2019). Y finalmente otro método llamado “Jose Antonio Avilez Izquierdo”, en el cual para detectar metástasis en melanomas de piel se realiza una clasificación con base en cuatro patrones de colores: azul, rosado, café y patrones mezclados (Avilés-Izquierdo et al., 2019).

2.3.4 Inteligencia artificial

La definición de la inteligencia artificial (IA) ha cambiado con el paso del tiempo, pero su principio siempre se ha tratado de construir máquinas o programas capaces de pensar como humanos y con habilidades de observar, razonar, aprender y resolver problemas.

La IA se puede categorizar por 3 niveles según su funcionalidad, son:

IA General: Capaz de ejecutar tareas cognitivas con la precisión del cerebro humano.

IA Estrecha: aplicaciones donde la máquina puede ejecutar una tarea específica mejor que un humano. La mayoría de las investigaciones actuales en IA suceden en esta área.

IA Fuerte: Las máquinas superan al cerebro humano en varias tareas.

2.3.5 Redes neuronales artificiales

Los modelos de redes neuronales artificiales se entienden como un grupo de unidades básicas de procesamiento, los cuales operan en las entradas dadas para procesar la información y generar los resultados deseados. hay 2 tipos de redes neuronales, la primera se llama redes Feed-Forward qué es cuando el flujo de la información va dirigida en 1 sola dirección, si la red es considerada como una gráfica con neuronas como sus nodos, las conexiones entre los nodos son tales qué no hay bucles o ciclos en el gráfico por ejemplo CNNs (convolutional neural networks).

También están las redes Feed-back como su nombre lo dice las redes feedback tienen conexiones qué forman los bucles dirigidos, esta arquitectura permite generar secuencias de tamaños arbitrarios y muy grandes. Estás redes tienen la capacidad de memorización y pueden almacenar información y relaciones de secuencia en su memoria interna los ejemplos son las arquitecturas RNN (recurrent neural Network).

2.3.6 Redes neuronales artificiales convolucionales

Las redes neuronales convolucionales son una de las categorías de redes más conocidas y usadas, puesto que son para datos muy grandes, un ejemplo de ello son las imágenes y los videos. Las redes convolucionales tienen un funcionamiento similar a las estándar, pero estas son esenciales en dónde se requiere de aprender patrones de entradas de altas dimensiones como lo son las imágenes y los videos.

Una CNN (Red Neuronal Artificial) aprende a fijar una imagen dada a su categoría correspondiente mediante la detección de una serie de representaciones de características abstractas, que van desde las más básicas hasta las más complejas. Estas características discriminatorias se usan luego dentro de la red entrenada para poder realizar la predicción la categoría correcta a la que una imagen de entrada pertenece (“A Guide to Convolutional Neural Networks for Computer Vision | Synthesis Lectures on Computer Vision,” 2018).

2.3.7 Deep learning y transfer learning

El aprendizaje profundo o *deep learning* es una técnica en inteligencia artificial que consiste en un aprendizaje automático, el cual enseña a los computadores a hacer lo que le resulta fácil a los humanos aprendiendo mediante ejemplos.

Los modelos de aprendizaje profundo se entran mediante un amplio conjunto de datos etiquetados y arquitecturas de redes neuronales o Neural Networks (NN) formadas por distintas capas, así obteniendo resultados con una precisión que incluso supere el rendimiento humano. Las redes neuronales tienen similitud con los

sistemas nerviosos biológicos y, por lo tanto, están constituidas por un conjunto de unidades llamadas neuronas o nodos que están conectados unos con otros.

Transfer learning: *Transfer learning* es una técnica en el campo del aprendizaje automático que implica transferir conocimiento de un dominio fuente a un dominio objetivo para mejorar el rendimiento en la tarea objetivo. En el contexto del aprendizaje profundo, el transfer learning implica reutilizar los conocimientos aprendidos por un modelo pre-entrenado en un dominio fuente (como un conjunto de datos grande y general) y adaptarlo para una tarea relacionada en el dominio objetivo (donde los datos pueden ser limitados o diferentes). (Jeffrey Theodore Heaton, 2017).

CAPÍTULO III

3 METODOLOGÍA

En este apartado se presenta la metodología implementada para la detección automática de cáncer de piel melanoma, haciendo uso de métodos de aprendizaje profundo a través de diferentes arquitecturas para clasificación de las imágenes.

Este proyecto consta de 3 objetivos específicos y cada uno de los cuales tiene 3 actividades a realizar para llegar al objetivo general.

Inicialmente se comienza descargando la base de datos para un total de 4000 imágenes, la mitad siendo de cáncer de piel tipo melanoma y la otra mitad no. Luego se realiza la fase de investigación donde se encuentra la mejor técnica de inteligencia artificial para clasificar cáncer de melanoma, en esta investigación crea un modelo con muchas conexiones y prueba los tres optimizadores de tasa de aprendizaje que usa Matlab para *deep learning*: RMSprop, SGMD y Adam. Se hace otro modelo pero aplicando *transfer learning* con los mismos optimizadores. Después de la investigación se selecciona el modelo con el optimizador que da mejores resultados, para realizar el diseño de la interfaz y finalmente se le realizan las respectivas pruebas al sistema. A continuación se observa el esquema metodológico (*figura 6*).

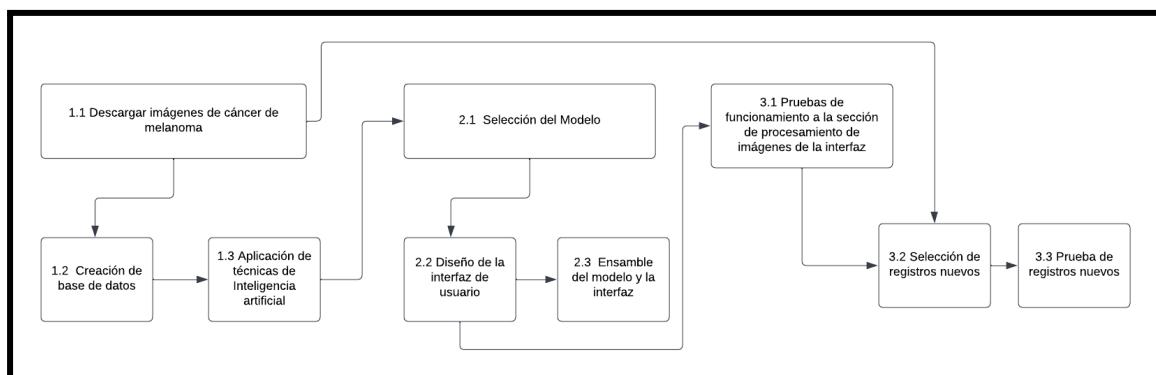


Figura 6. Esquema metodológico. (Autoría).

3.1 BASE DE DATOS

Para el desarrollo de este proyecto se usó la base de datos de "The International Skin Imaging Collaboration" (ISIC archive), la cual es una asociación creada entre diferentes entidades en el mundo para colaborar y facilitar el acceso a imágenes de la piel para fines investigativos. El objetivo de "The International Skin Imaging Collaboration" es una asociación entre el mundo académico y la industria diseñada para facilitar las tecnologías digitales de imágenes de la piel para ayudar a reducir la mortalidad por melanoma.

De manera específica se usó la base de datos de ISIC en la sesión de melanoma, la cual cuenta con un total de 4000 imágenes, divididas en 80 % para SuperTraining, que son 3200 (1600 benignas y 1600 malignas) y 20 % para SuperTest, que son 800 (400 benignas y 400 malignas).

3.2 INVESTIGACIÓN DE TÉCNICAS DE INTELIGENCIA ARTIFICIAL

Para determinar las mejores técnicas de inteligencia artificial para este tipo de proyecto, el estado del arte ayuda, ya que es una recopilación de proyectos que se asemejan al objetivo del nuestro. A partir de esta investigación se selecciona la técnica a trabajar, en este caso se usa *Deep Learning* con redes neuronales que se facilita en cuanto a la clasificación de imágenes y *transfer learning* que aprovecha el conocimiento previo, reduce el tiempo de entrenamiento, mejora el rendimiento, actúa como una forma de regularización y es flexible en su aplicación.

3.3 PROCESAMIENTO DE IMÁGENES

Entonces se realizó un redimensionamiento en el tamaño de todas las imágenes en RGB a $224 \times 224 \times 3$ píxeles, debido a que las arquitecturas de las redes neuronales admiten un tamaño específico y además para facilitar su trabajo al clasificar las imágenes.

Para la creación del modelo se toma un total del 80 % del dataset, es decir 3200 imágenes destinadas para entrenar el modelo (SuperTraining). Las 800 imágenes restantes serán SuperTest, destinadas para probar el modelo y seleccionar el porcentaje real con el que va a trabajar el modelo.

3.4 CÓDIGO Y SELECCIÓN DEL SOFTWARE

Se lleva a cabo una investigación para determinar qué tipo de lenguaje y software de programación se va a utilizar, teniendo en cuenta algunos parámetros clave: el alcance funcional del proyecto, los conocimientos previos del software y la flexibilidad para crear la interfaz. Después de una evaluación exhaustiva, se decide utilizar un marco de trabajo que permita aprovechar el *transfer learning* en el desarrollo del sistema.

Una vez seleccionado el software, se procede a implementar un modelo de *transfer learning* utilizando técnicas de *Deep Learning* para la clasificación de imágenes, específicamente para detectar la presencia de melanoma. Se elige un modelo pre-entrenado en un conjunto de datos grande y general, lo que permite al sistema capturar características relevantes de las imágenes de manera más efectiva, incluso con un conjunto de datos de melanoma relativamente pequeño.

Después de entrenar el modelo y verificar que funciona correctamente, se realiza un ajuste en el código para desarrollar la interfaz de usuario, lo que permite a los usuarios interactuar con el sistema de manera intuitiva y eficiente.(Para ver el algoritmo Ir al apartado *Algoritmo* al final del documento).

3.5 SELECCIÓN DEL DISEÑO DE INTERFAZ

Para la selección del diseño de la interfaz se realizaron varios 3 bocetos, con diferentes colores, el primer boceto (azul y verde claro), el segundo boceto (morado y negro) y por ultimo (naranja y gris), con el objetivo de buscar los colores mas amigables.

3.6 PRUEBAS DE FUNCIONAMIENTO

Se verifica que la interfaz cargue una imagen. Se cerciora que haya una lectura de la imagen que se cargó. Se verifica que el modelo clasifique y que muestre los resultados en la interfaz. Después se eligen el 20% de las imágenes de la base de datos, que en este caso son 800, para usarlas como casos nuevos de melanoma. Este se conoce como el conjunto de SuperTest. Y se hacen las pruebas de la interfaz con todo articulado.

CAPÍTULO IV

4 RESULTADOS Y ANÁLISIS DE RESULTADOS

En este capítulo se presentan los resultados obtenidos del proyecto, desde la creación del modelo hasta la aplicación de transfer learning, la comparativa de los tres optimizadores utilizados, junto con sus porcentajes de precisión. En el que se realizaron varias tablas comparativas y se mencionan los criterios para seleccionar el mejor modelo a partir de las medidas de bondad.

4.1 SELECCIÓN DEL SOFTWARE DE PROGRAMACIÓN

Para seleccionar el algoritmo a trabajar el modelo se hace una matriz de selección en la que se compara Matlab vs Python con los criterios de conocimiento, experiencia en el lenguaje, versatilidad que brinda el lenguaje y su complejidad.

Se le asignaron los pesos de importancia de 4 para conocimiento, 3 para experiencia, 2 para complejidad y 1 para versatilidad del lenguaje. Entonces se usa una escala de 1 a 3 siendo la mejor opción 3, y se comienza a llenar la matriz. Luego se multiplican por los pesos asignados y se llega a que dado al conocimiento y a la experiencia que los estudiantes tienen en matlab, el resultado de desarrollar el algoritmo en ese lenguaje es el mejor para el proyecto. (*Matriz de selección del algoritmo con escala de 1 a 3*).

Lenguaje	Conocimiento (Peso: 4)	Experiencia (Peso: 3)	Versatilidad del lenguaje (Peso: 1)	Complejidad (Peso: 2)	Resultado
Matlab	$3 \times 4 = 12$	$3 \times 3 = 9$	$2 \times 1 = 2$	$1 \times 2 = 2$	25
Python	$1 \times 4 = 4$	$1 \times 3 = 3$	$3 \times 1 = 3$	$1 \times 2 = 2$	12

Tabla 1. Matriz de selección del algoritmo con escala de 1 a 3.

4.2 CREACIÓN DEL MODELO *DESDE CERO* (*From Scratch - Students Net*)

4.2.1 OPTIMIZADORES Y TASA DE APRENDIZAJE

Para encontrar el modelo desde el scratch se tiene presente que variando la tasa de aprendizaje el porcentaje de clasificación mejora o no. Sin embargo, sabiendo que esta técnica de aprendizaje profundo en *Matlab* permite explorar tres optimizadores que, tienen la función de ajustar los pesos internos de las capas de neuronas convolucionales (CNN) y ayudan a que el modelo mejore su clasificación, el proyecto se adentra a explorar cuál optimizador (*RMSprop*, *Sgmd* y *Adam*) junto con la variación de la tasa de aprendizaje, da mejores porcentajes de validación *desde cero* (*from scratch*) creada por los estudiantes.

4.2.2 OPTIMIZADOR RMSprop

El primer optimizador probado es el *RMSprop* el cual utiliza la propagación cuadrática media para optimizar los pasos que da la red neuronal haciendo los saltos que la tasa de aprendizaje (*learn rate - LR*) le estipula.

En la *Figura 7* tenemos un LR de 1.37e-05 con este optimizador da un *validation ACCURACY* del 75.83 %.

Para entender las figuras, tenemos dos gráficas por cada entrenamiento. La primera gráfica (*Accuracy[%] vs Iteraciones[sin dimensiones]*), la exactitud (Accuracy) que tiene tres líneas. De color azul, la que representa el valor del porcentaje de (Accuracy) del *Training (smoothed)*, un azul suave del porcentaje de *Training* real y por ultimo el porcentaje de *Validation* de color negro punteada.

La segunda gráfica (*Loss[sin dimensiones] vs Iteraciones[sin dimensiones]*), representa la pérdida para los mismos tres parámetros mencionados, solo con la excepción de que Training es de color naranja. Este *LOSS* se encarga de cuantificar la diferencia entre el valor real por iteración versus el valor que estimó la red, por eso *no tiene dimensiones en la gráfica*.

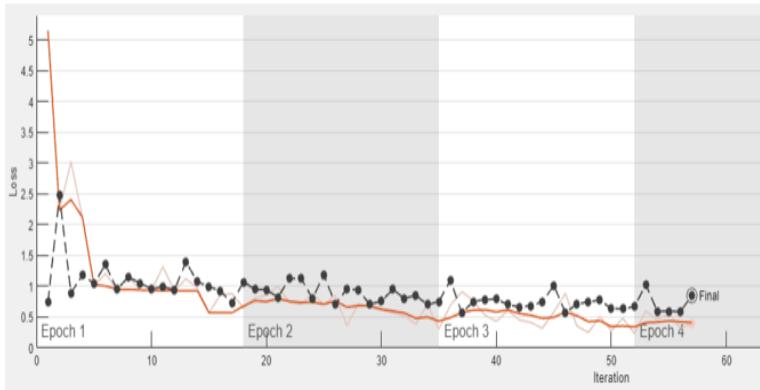
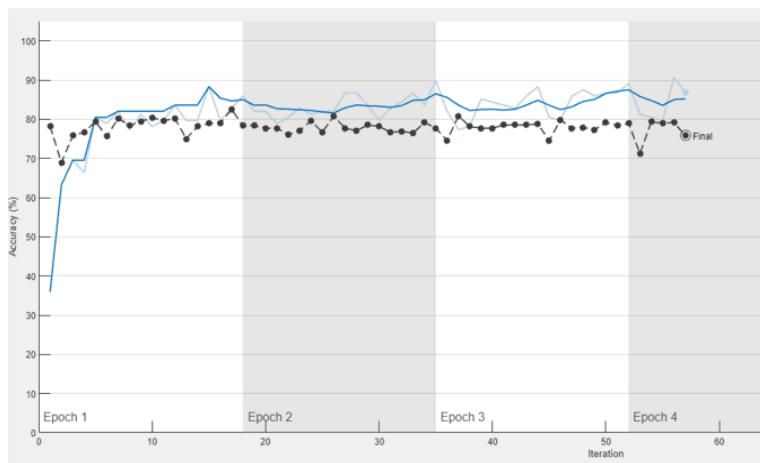




Figura 7. 1er optimizador RMSprop con un porcentaje de 75.83 %.

RESULTADOS				
Precisión(%)	Tiempo Transcurrido	# De epoch	# De iteraciones	Tasa de aprendizaje
75,83	1:08:52	4 de 8	57 de 136	1.37e-05

Tabla 2. 1er Resultado del Optimizador RMSprop.

Al comenzar a cambiar el LR aumentando 10% su valor, el modelo mejora su validación con un 79.17 % para un LR del 1.66e-05 (Ver *Figura 8*)

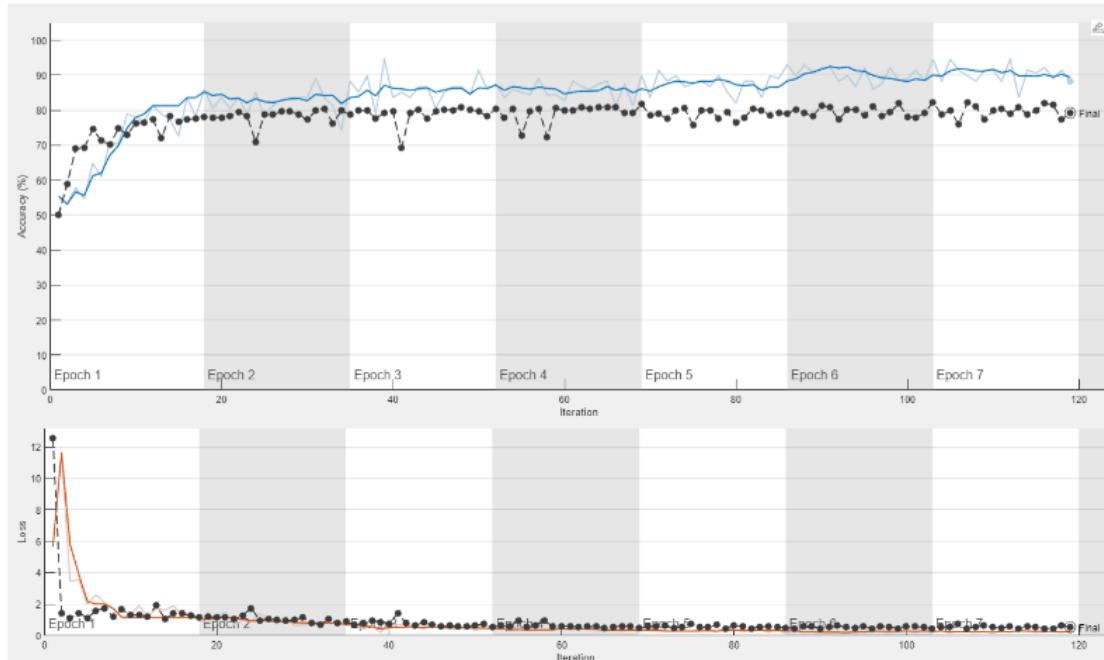


Figura 8. 1er optimizador RMSprop con un porcentaje de 79.17 %.

RESULTADOS				
Precisión(%)	Tiempo Transcurrido	# De epoch	# De iteraciones	Tasa de aprendizaje
79,17	2:22:39	7 de 8	119 de 136	1.66e-05

Tabla 3. 2do Resultado del Optimizador RMSprop.

Así que se continuó aumentando el *LR* de la forma que se comenta anteriormente ya que la curva del *LOSS* cae bruscamente, por lo que se quiere un número cercano al anterior *LR*. Entonces se encuentra para un 1.95e-05 de *LR* encontramos una validación del 80.62% ya que por encima de esta tasa, la validación comienza a disminuir. (Ver Figura 9)

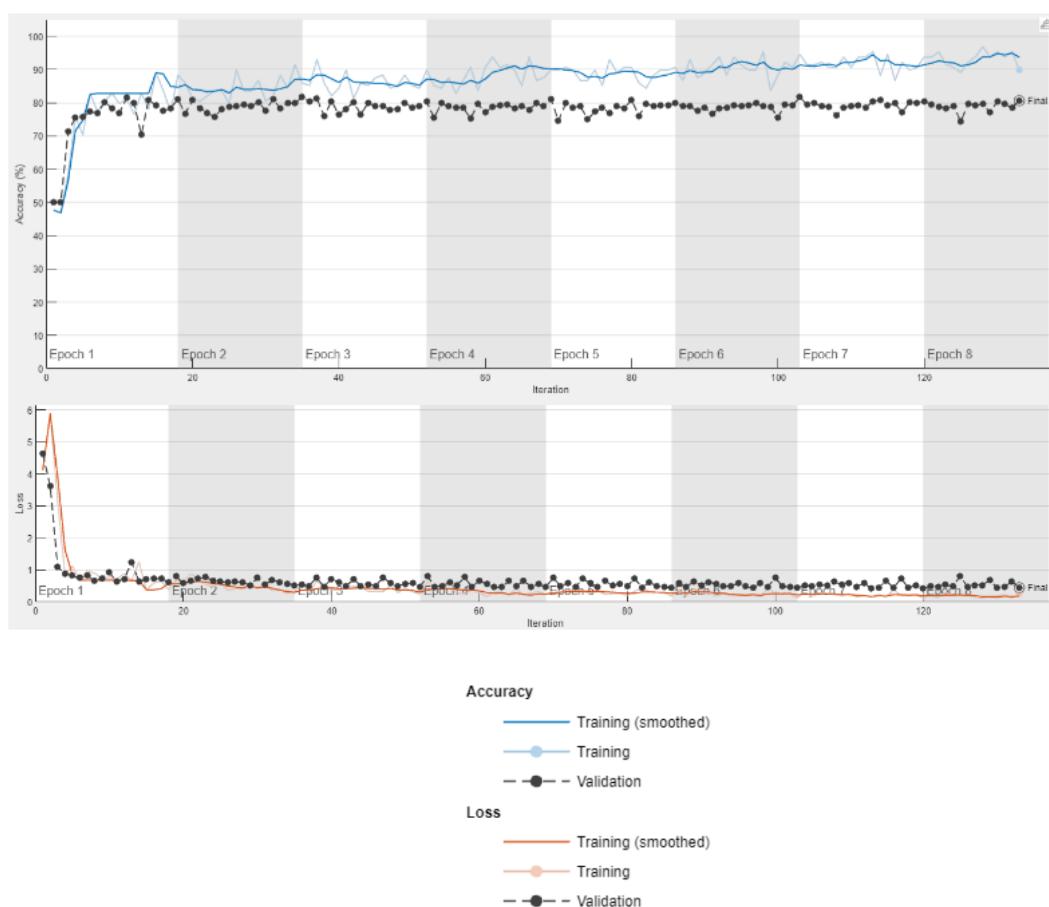


Figura 9. 1er optimizador RMSprop con un porcentaje de 80.62 %.

RESULTADOS				
Precisión(%)	Tiempo Transcurrido	# De epoch	# De iteraciones	Tasa de aprendizaje
80,62	2:35:03	8 de 8	133 de 136	1.95e-05

Tabla 4. 3er Resultado del Optimizador RMSprop.

Siempre la gráfica de la pérdida, comienza con un valor de *Loss* alto ya que la red es ‘*ignorante*’ al no conocer suficientemente los datos. Y, por cada iteración va aprendiendo, por lo que la *pérdida* del valor predicho en la iteración anterior con la salida nueva es menor. Por tal motivo la gráfica debe ir cayendo, pero cabe aclarar que lo debe hacer con un curva suave donde tienda a un valor cercano a *cero* (0).

Por eso dejamos fijo este LR de 1.95e-05. Y, se ingresa dentro del modelo dos *layers* que hacen que cada Epoch, el *LR*, pierda un 0.2 en su valor (*LearnRateDropFactor = 0.2 & LearnRateDropPeriod = 1 epoch*). Para lo cual resulta un 81.88 %; siendo el mejor porcentaje de validación (ver *Figura 10*) que posee el modelo para este optimizador. No obstante se desea que la curva de validación sea más plana para que el modelo sea más estable, por lo que se prueba los demás optimizadores.

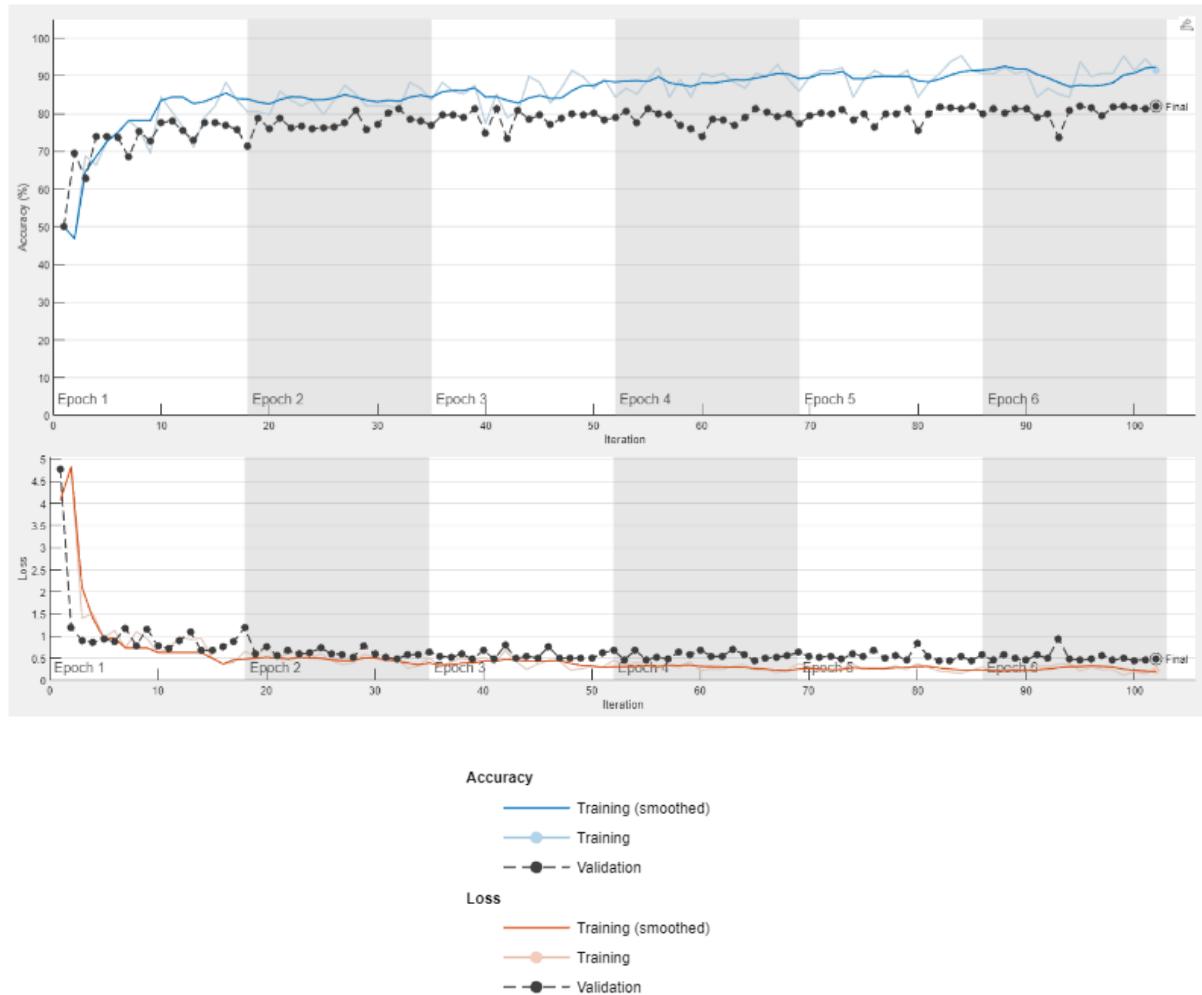


Figura 10. 1er optimizador RMSprop con un porcentaje de 81.88 %.

RESULTADOS				
Precisión(%)	Tiempo Transcurrido	# De epoch	# De iteraciones	Tasa de aprendizaje
81,88	01:59:35	6 de 8	102 de 136	1.95e-05

Tabla 5. 4to Resultado del Optimizador RMSprop.

4.2.3 OPTIMIZADOR SGMD

Para el optimizador de aprendizaje profundo de *descenso de gradiente estocástico* (SGMD) se compara contra el primer optimizador con su mejor LR y se encuentra un 78.54 % de validación. (Ver *Figura 11*)

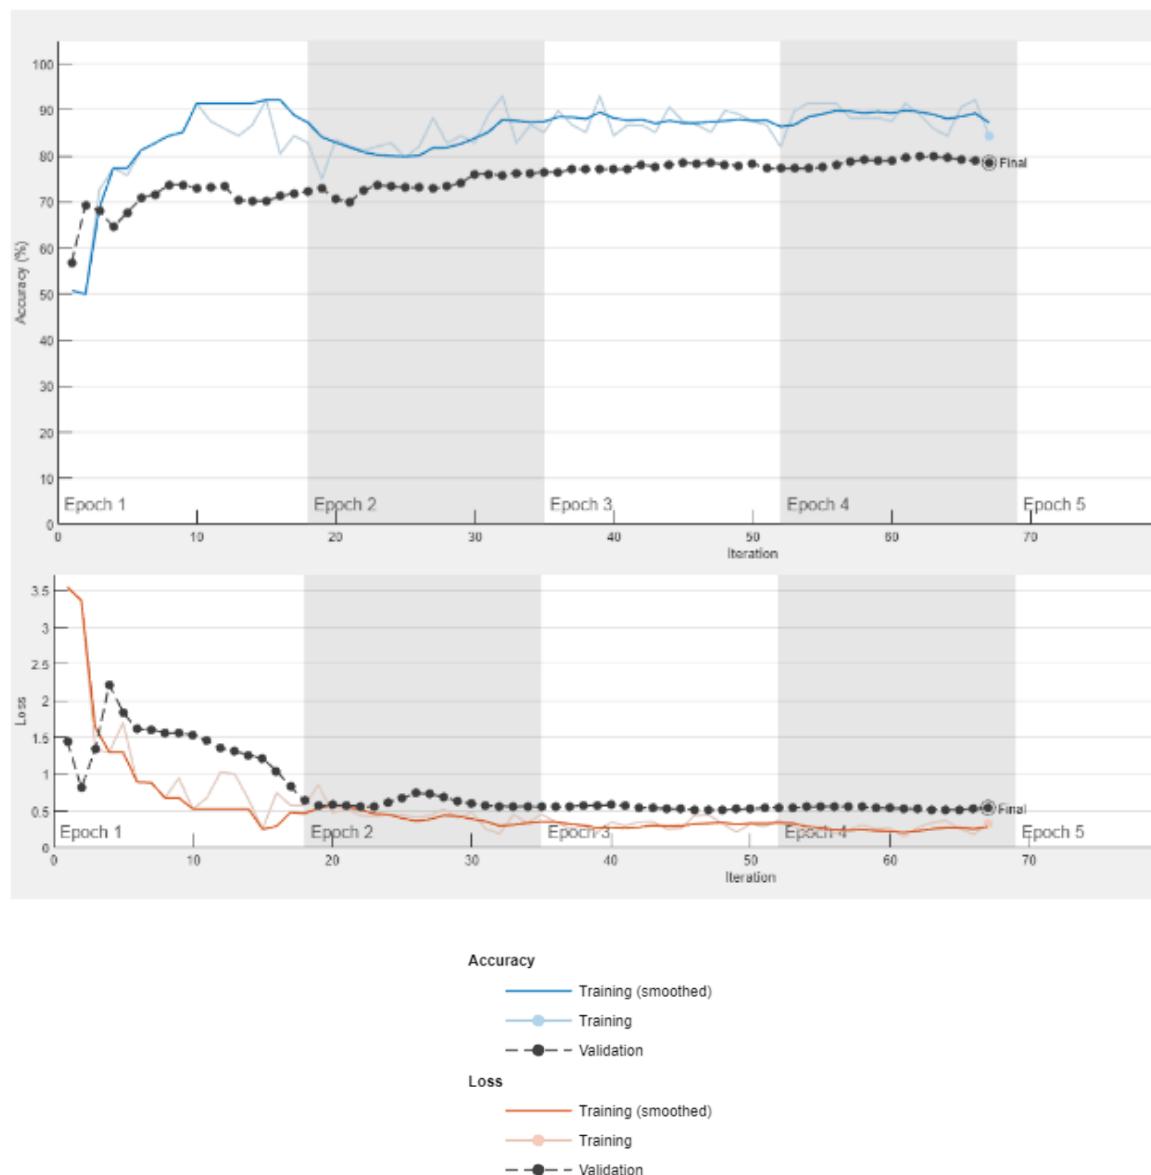


Figura 11. 2do optimizador SGMD con un porcentaje de 78.54 %.

Ahora se le ingresa al modelo un LearnRateDropFactor del 0.2 y LearnRateDropPeriod por cada 1 Epoch de la misma manera que dió el mejor porcentaje de accuracy para el Optimizador RMSprop, no obstante la validación decrece a un 77.08 % teniendo un LR del 1.95e-05. (Ver Figura 12)

RESULTADOS

Precisión(%)	Tiempo Transcurrido	# De epoch	# De iteraciones	Tasa de aprendizaje
78,54	01:20:28	4 de 8	67 de 136	1.95e-05

Tabla 6. 1er Resultado del Optimizador SGMD.

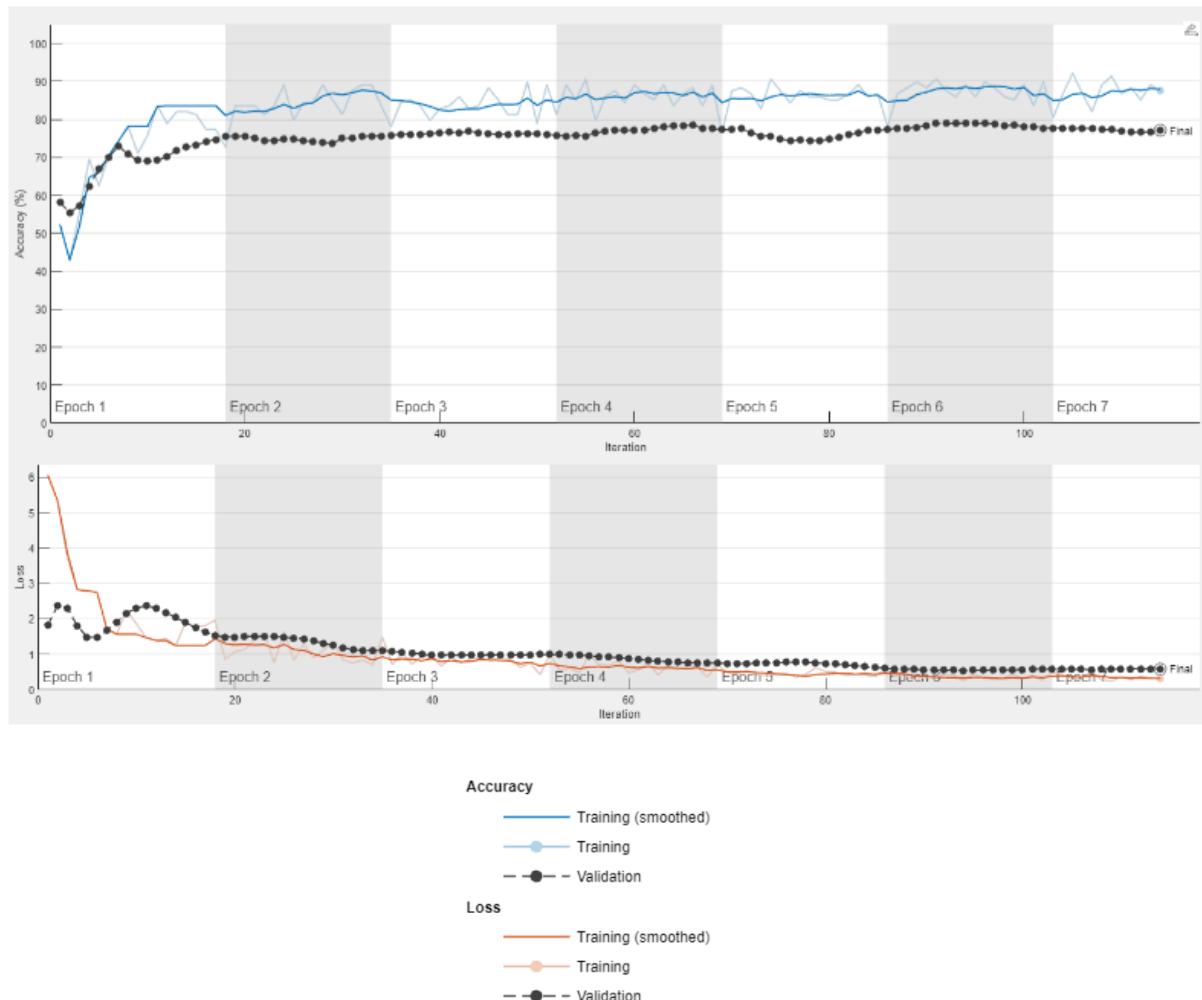


Figura 12. 2do optimizador SGMD con un porcentaje de 77.08 %.

RESULTADOS

Precisión(%)	Tiempo Transcurrido	# De epoch	# De iteraciones	Tasa de aprendizaje
77,08	02:39:58	7 de 8	114 de 136	1.11e-05

Tabla 7. 2do Resultado del Optimizador SGMD.

4.2.4 OPTIMIZADOR Adam

El *Adam* es un optimizador de *estimación de momentos adaptativos* dentro de los pesos de las CNN. Entonces se prueba el primer LR usado con el optimizador RMSprop (1.37e-05) para este optimizador y se halla un 77.08 % de validación. Todos los modelos de entrenamiento realizados anteriormente con los diferentes optimizadores tienen un criterio para utilizar lo mejor posible el coste computacional. Este es el Validation Patience o el Early Stopping, el cual tiene una paciencia de 20, lo que significa que si en el entrenamiento cae el porcentaje de validación, tiene 20 iteraciones para llegar a igualarla o superarla, de lo contrario se para el entrenamiento como sucede en la *figura 14*.

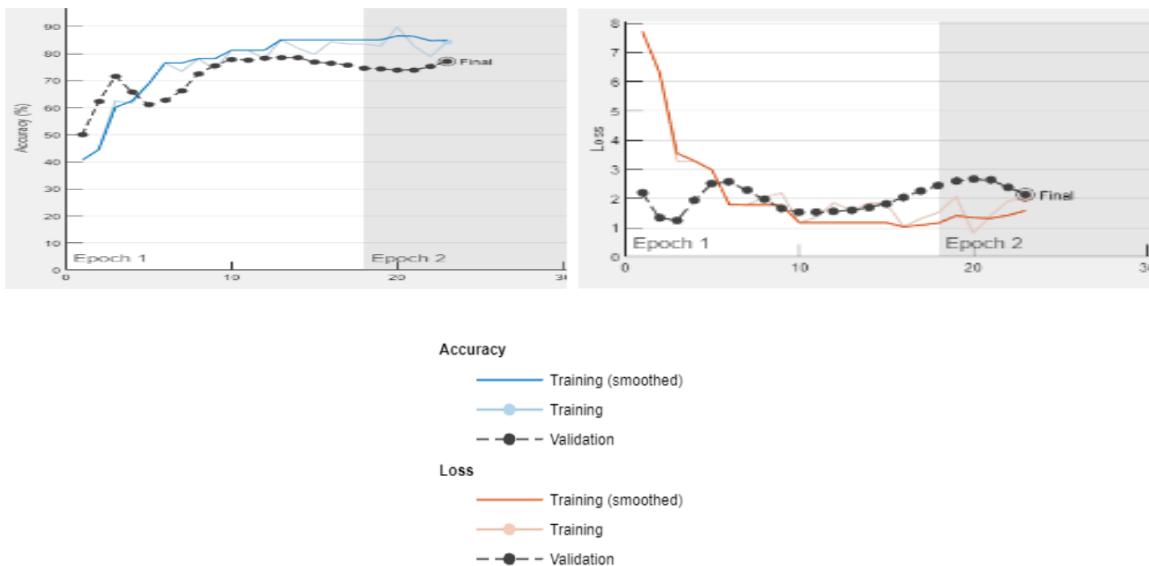


Figura 13. 3er optimizador Adam con un porcentaje de 77.08 %.

RESULTADOS				
Precisión(%)	Tiempo Transcurrido	# De epoch	# De iteraciones	Tasa de aprendizaje
77,08	0:32:57	2 de 8	23 de 136	1.37e-05

Tabla 8. 1er Resultado del Optimizador Adam.

Con el LR del 1.95e-05 encontramos un 79.58 % de validación. Se observa entonces que el optimizador adam con los mismos criterios de tasas de aprendizaje tiene mejores porcentajes de validación con menores iteraciones (ver *figura 15*).

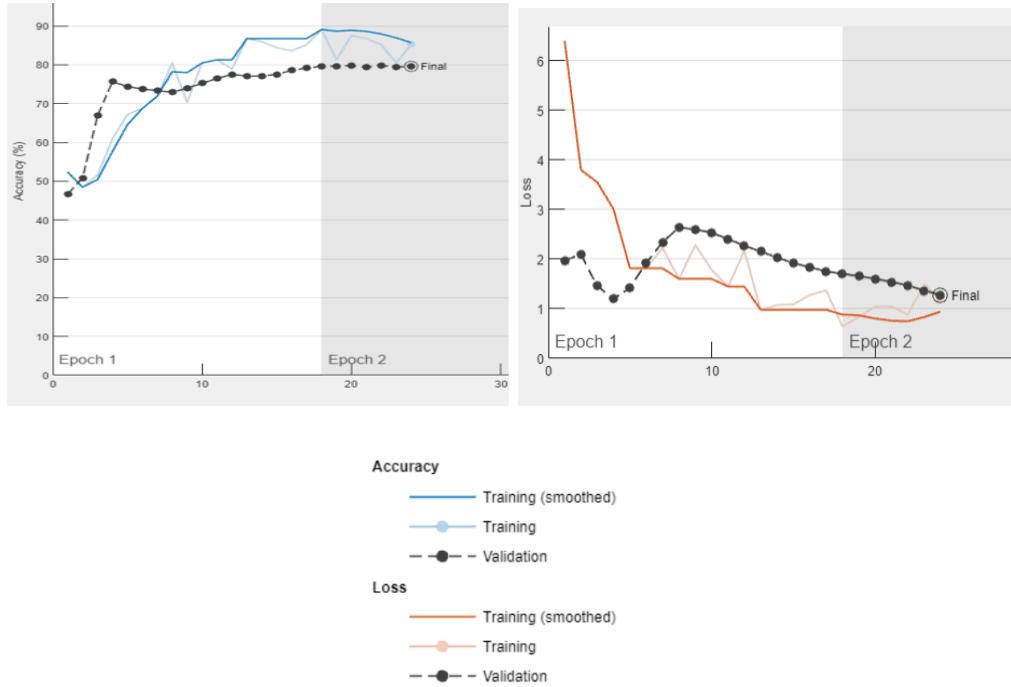


Figura 14. Gráficas del 3er optimizador Adam con un porcentaje de 79.58 %.

RESULTADOS				
Precisión(%)	Tiempo Transcurrido	# De epoch	# De iteraciones	Tasa de aprendizaje
79,58	0:28:58	2 de 8	24 de 136	1.95e-05

Tabla 9. 2do Resultado del Optimizador Adam.

Ahora bien, comenzando a aumentar la tasa de aprendizaje comparado el criterio del aumento del LR cada 10% cercano, para tener un mejor porcentaje de validación y verificando que en los diferentes experimentos, los valores de *LR* cercanos, mejoraron la clasificación; con esto, se encuentra que con un *LR* del 2.7e-05 tenemos un 80.00 % de *accuracy* en la validación (Ver *Figura 16*) porque por encima de esta tasa el porcentaje, con este optimizador y sus *layers*, el porcentaje de clasificación comienza a **disminuir**.

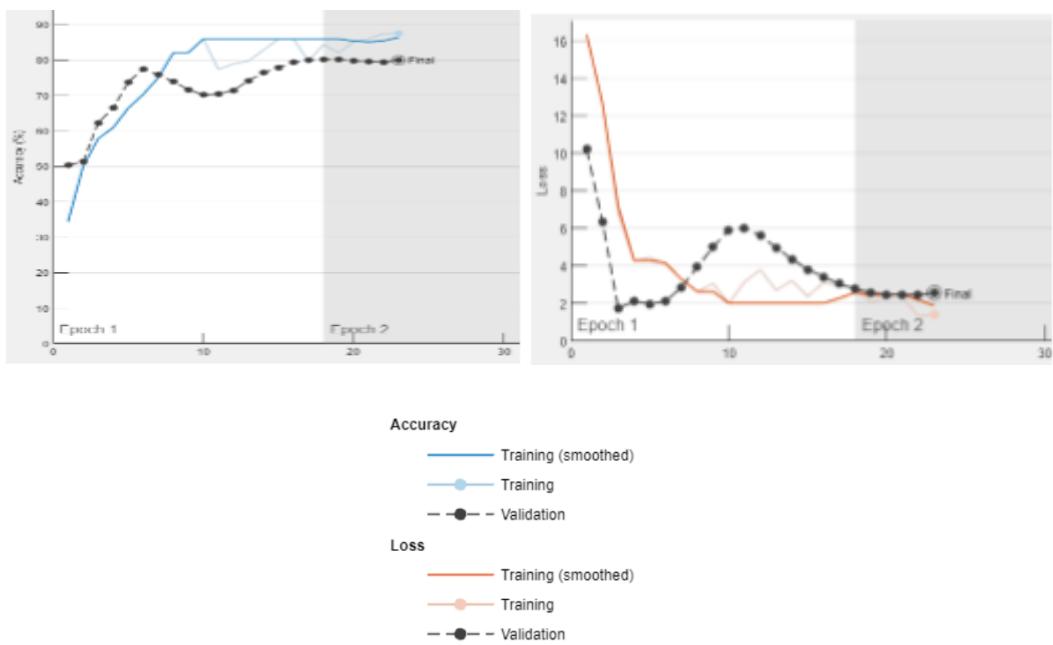


Figura 15. 3er optimizador Adam con un porcentaje de 80.00 %.

RESULTADOS				
Precisión(%)	Tiempo Transcurrido	# De epoch	# De iteraciones	Tasa de aprendizaje
80	0:35:45	2 de 8	23 de 136	2.7e-05

Tabla 10. 3ro Resultado del Optimizador Adam.

Así mismo, se encontró que con LR 2.7e-05 y añadiendo nuevamente un LearRateDropFactor del 0.2 por cada epoch tenemos un 81.04 % de validación como se observa en la *Figura 17*.

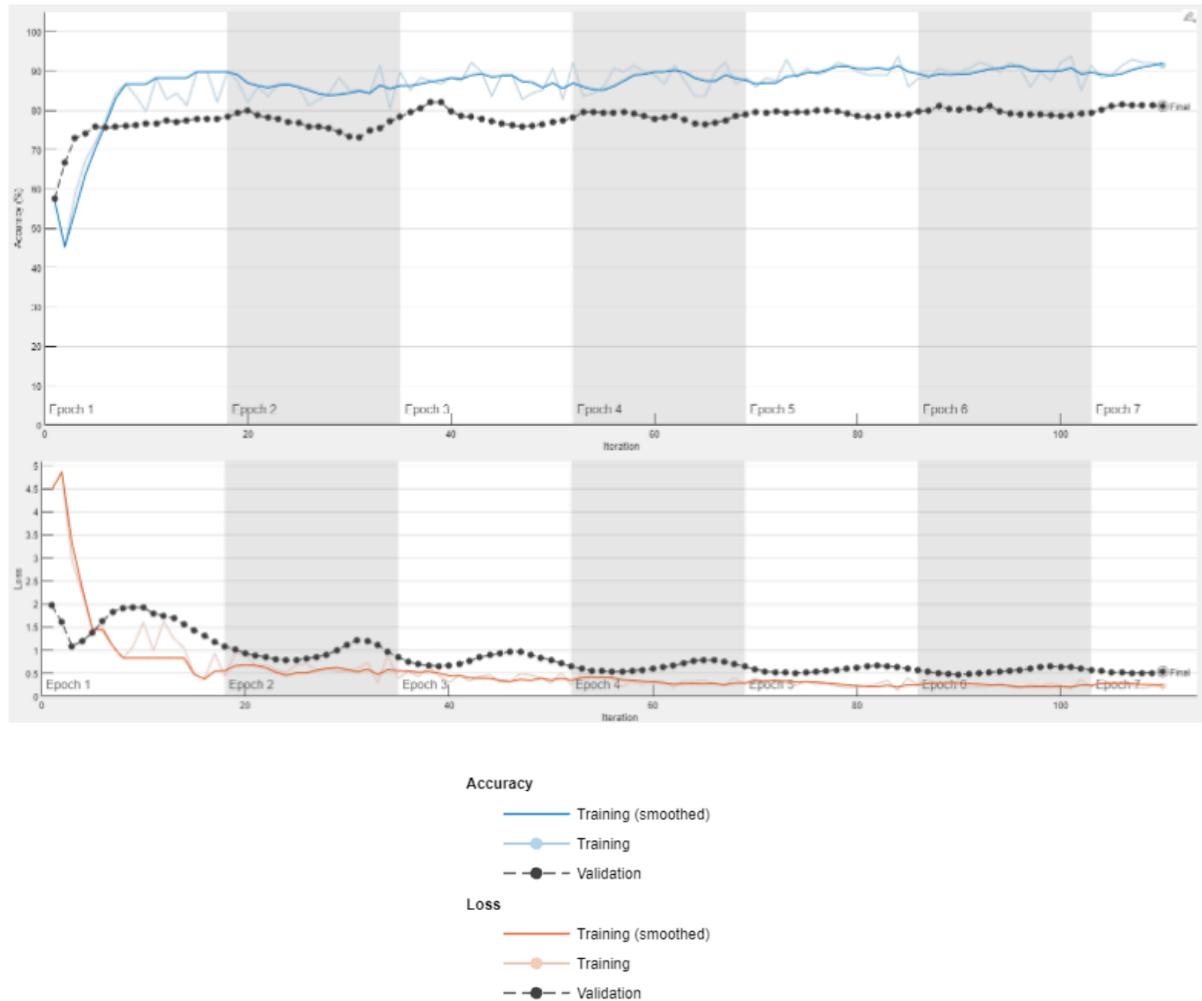


Figura 16. 3er optimizador Adam con un porcentaje de 81.04 %.

RESULTADOS				
Precisión(%)	Tiempo Transcurrido	# De epoch	# De iteraciones	Tasa de aprendizaje
81,04	02:21:52	7 de 8	110 de 136	2.7e-05

Tabla 11. 4to Resultado del Optimizador Adam.

4.2.5 ANÁLISIS DE SELECCIÓN DEL MODELO CREADO FROM SCRATCH

(STUDENTS NET)

Para seleccionar cuál es el modelo, se comparan los resultados de los experimentos anteriores en la *tabla 12*. El mejor optimizador debe tener porcentajes que, de acuerdo a la literatura, estén mínimo por encima del 80% de *accuracy*, los cuales

serán buenos pero no son suficientes para tener resultados prometedores para detectar una enfermedad

Optimizador	Tasa de aprendizaje (Learn Rate) $\times 10^{-5}$ [sin unidades]	Validación [%]	Iteraciones [#]	Caída de la tasa de aprendizaje (LRDropFactor) []	Periodo de caída de la tasa de Aprendizaje (LRDropPeriod) [Epoch]
RMSprop	1.37	75.83	57	—	—
	1.66	79.17	119	--	--
	1.95	80.62	133	--	--
	1.95	81.88	102	0.2	1
SGMD	1.95	78.54	67	—	—
	1.95	77.08	83	0.2	1
	—	—	—	—	—
Adam	1.37	77.08	23	—	—
	1.95	79.58	24	—	—
	2.7	80.00	23	—	—
	2.7	81.04	110	0.2	1

Tabla 12. Comparativa de todos los porcentajes arrojados por los 3 optimizadores.

El modelo que se selecciona es con el optimizador adam con un 81.04% de validación en exactitud (Accuracy)

Entonces este modelo de Adam se procede a sacarle las medidas de bondad a partir de sus matrices de confusión para los tres conjuntos (Entrenamiento, Validación y Prueba)

Students Net - Medidas de Bondad			
	Entrenamiento	Validación	Prueba
Exactitud	77.72%	76.88%	77.29%

Sensibilidad	94.38%	92.92%	94.17%
Precisión	70.80%	70.35%	70.40%
Especificidad	61.07%	60.83%	60.24%
Puntuación F1	80.90%	80.07%	80.57%

Tabla 13. Medidas de bondad de Students Net

Para lo cual se deduce que su cambio en el valor de la exactitud implica que se deba hacer una técnica más robusta dentro del aprendizaje profundo.

La arquitectura desde cero *from scratch* - *Students Net* posee la siguiente estructura. Ver *figura 17*.

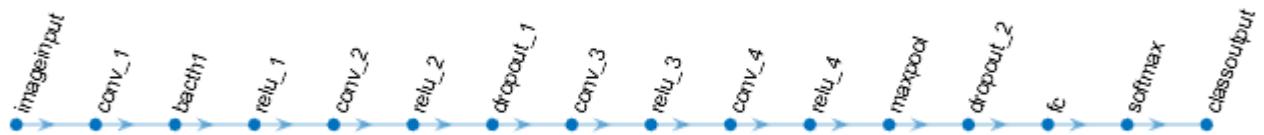


Figura 17. Estructura de Students Net.

A continuación se explica los Layers que posee el modelo:

Image input: Es una capa que recibe las imágenes en una red neuronal y normaliza los datos entre 0 y 1. Aquí es donde se redimensiona las imágenes.

Conv 1: Es un convolution Layer el cual trabaja aplicando filtros convolucionales deslizantes a una entrada que puede ser de 1D, 2D o 3D.

Bacth1: Es una capa de normalización que elige un grupo de datos en cada observación para cada canal de manera independiente. Funciona muy bien con funciones de activación tipo Relu.

Relu 1: Es una función de activación que para cualquier valor menor a cero, se convierte en cero, y para mayores de cero sigue siendo ese mismo valor. Tiene el trabajo de darle más complejidad a los cambios de los pesos y bias internos de la Red para que el sistema aprenda más rápido.

Conv 2: Es otro filtro convolucional en otro lugar de la red.

Relu 2: Es la segunda función Relu en otro lugar de la red.

Dropout 1: Es una capa de abandono con una probabilidad que se selecciona. Para este modelo posee un 60 % de probabilidad. También es conocido como un layer que prende y apaga las neuronas dependiendo su valor.

Conv 3: Tercer layer de filtro convolucional

Relu 3: Tercera función de activación Relu.

Conv 4: Cuarto filtro convolucional.

Relu 4: Cuarta función de activación Relu.

Max Pooling: Es una capa que hace un submuestreo. Agrupando las entradas a ella, las divide en grupos de rectángulos y de ese grupo calcula el valor máximo.

Dropout 2: Este también se programa con un 60 % de probabilidad.

Fully connected (fc): Layer de clasificación, en donde se le dice a la red cuántas capas de salida debe tener el modelo.

Softmax: Es una capa que aplica la función de activación softmax a la entrada.

Classoutput: Capa de clasificación.

El algoritmo con el que se programa las capas de la red de aprendizaje profundo se presentan al final del documento.

Es importante saber que todos los entrenamientos se hacen con un criterio en donde, si el porcentaje de validación cae, y en *X iteraciones de paciencia*, aún no la ha igualado o superado, el entrenamiento se termina. Esto es conocido como *early-stopping* y se selecciona una paciencia de 20 *iteraciones*, después de

experimentar valores de 8 en adelante, donde le permitirá a la validación recuperarse sin llegar a que el modelo se sobreajuste. (*Overfitting*).

4.3 CREACIÓN DEL MODELO CON TRANSFER LEARNING

El *transfer learning* es una técnica dentro del aprendizaje profundo que permite enseñarle nuevas imágenes a grandes redes pre entrenadas con grandes bases de datos. Por eso se va a probar tres conocidas redes pre entrenadas: *Alex-net*, *Res-Net 50* y la *Vgg 16*. El fin es enseñarles la enfermedad y encontrar medidas de bondad que permitan seleccionar el *mejor modelo* para la detección de este tipo de cáncer con esta técnica. La metodología consiste en sintonizar las opciones de entrenamiento para probar cual de las anteriormente mencionadas redes clasifica mejor. Para una mejor generalización y aprendizaje de los datos se realiza una validación cruzada con $K = 5$.

SINTONIZACIÓN DE PARÁMETROS: Dentro de las opciones de entrenamiento se tienen parámetros que se pueden modificar a las redes pre entrenadas, a fin de ver que tan fácil se les hace aprender una información nueva. Esos parámetros que se modificarán en esta metodología son el *Batch Size*, el *Learning Rate* y el algoritmo optimizador de aprendizaje.

- *Batch Size*: Es un dato que se usa en potencias de 2 y para coste computacional de los diseñadores del proyecto se seleccionan los valores de 32 y 64.
- *Learning Rate*: Se seleccionan en saltos potencias de 1000, tales como: 1, 10^{-1} , 10^{-2} , 10^{-3} , 10^{-4} , 10^{-5} , 10^{-6}

- *Algoritmo optimizador de aprendizaje:* En matlab se puede sintonizar tres optimizadores diferentes, siendo: El *rmsprop*, *adam* y *sgdm*.

Entonces teniendo en cuenta estos parámetros a sintonizar para hacer los experimentos se toman las buenas prácticas de redes neuronales convolucionales para encontrar los respectivos porcentajes de *training*, *validation* y *test*; para seleccionar el modelo. El modelo elegido tendrá el mejor porcentaje de *validation* en su respectiva sintonización.

Los resultados del modelo se presentan en tablas que muestran los porcentajes de Exactitud (*Accuracy*) para las fases de entrenamiento, validación y prueba, aplicados a todas las redes pre entrenadas. Cada una de estas redes se evaluó con tres optimizadores diferentes. Además, se incluyen las gráficas correspondientes a cada experimento, donde se combinan las redes pre entrenadas con los distintos optimizadores. En estas gráficas, el eje y representa el porcentaje de exactitud y el eje x la tasa de aprendizaje, permitiendo observar el comportamiento del entrenamiento en función de esta última variable.

A continuación se tiene la tabla de los porcentajes de Exactitud (*Accuracy*) para *training*, *validation* y *test* para *Alexnet* con el optimizador *rmsprop*:

%Exactitud para Alexnet						
Learn Rate	Optimizador Rmsprop					
	<i>Batch Size</i>					
	32			64		
	Entrenamiento(%)	Validación(%)	Prueba(%)	Entrenamiento(%)	Validación(%)	Prueba(%)
1	59.04	58.96	59.11	59.04	58.96	59.11
10^{-1}	59.04	58.96	59.11	59.04	58.96	59.11
10^{-2}	59.04	58.96	59.11	59.04	58.96	59.11
10^{-3}	59.04	58.96	59.11	57.77	57	57.88
10^{-4}	97.47	94.84	94.82	99.36	93.85	95.81
10^{-5}	99.89	98.77	98.76	99.57	96.31	97.53
10^{-6}	96.41	94.34	95.81	91.19	89.18	90.39

Tabla 14. Porcentajes de Accuracy para training, validation y test para Alexnet con el optimizador rmsprop.

Su mejor porcentaje de Clasificación se halla con el valor más alto del conjunto de validación, siendo este un *Learn Rate* para un *batch size* de 32 y de 64 también. Estos dos modelos se pasan a una tabla de los 18 campeones (Ver tabla 22 y 23) donde 9 serán para un *batch size* de 32 y 9 campeones para 64 *batch size*.

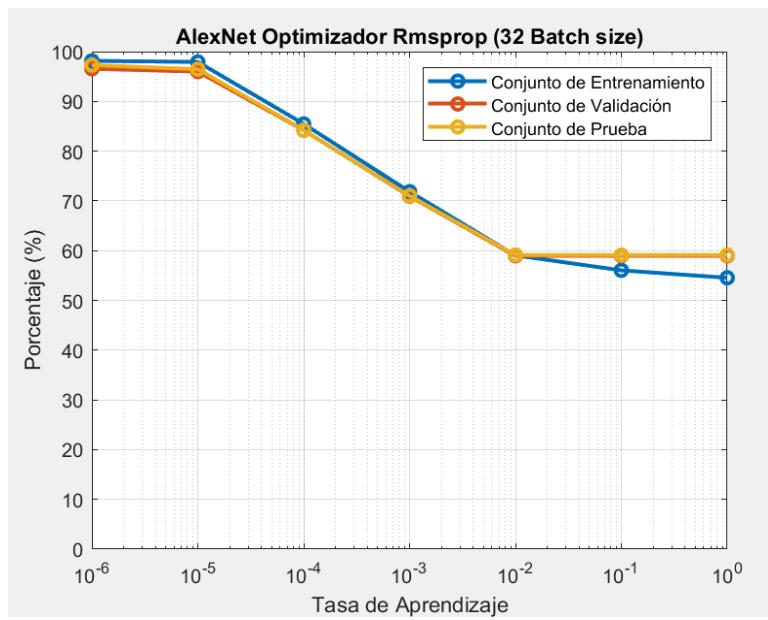


Figura 18. Gráfica porcentaje vs tasa de aprendizaje de la red Alexnet optimizador Rmsprop(32 Batch size).

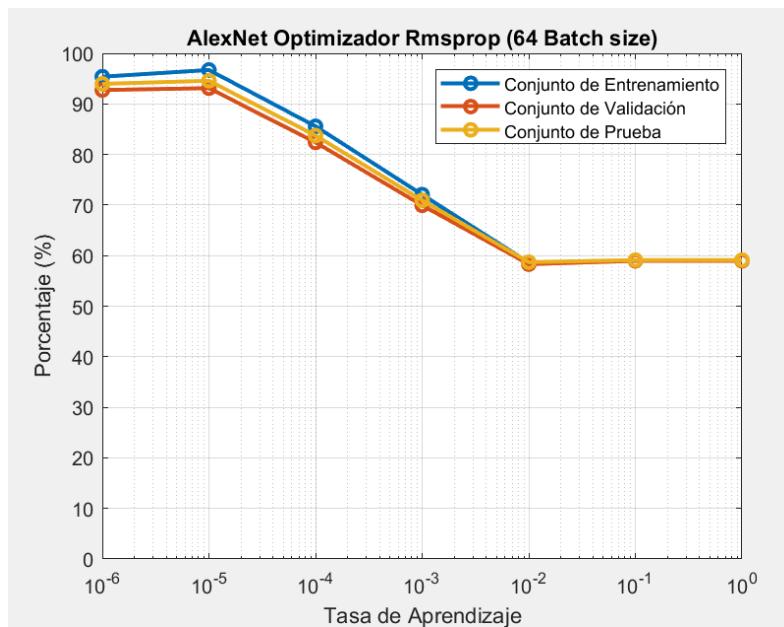


Figura 19. Gráfica porcentaje vs tasa de aprendizaje de la red Alexnet optimizador Rmsprop(64 Batch size).

A continuación se tiene la tabla de los porcentajes de Accuracy para *training*, *validation* y *test* para *Alexnet* con el optimizador *adam*:

%Exactitud para Alexnet						
Learn Rate	Optimizador Adam					
	Batch Size					
	32			64		
	Entrenamiento(%)	Validación (%)	Prueba (%)	Entrenamiento(%)	Validación(%)	Prueba (%)
1	40.95	41.03	40.88	40.95	41.03	40.88
10^{-1}	59.04	58.96	59.11	41.11	41.03	40.88
10^{-2}	59.04	58.96	59.11	59.04	58.96	59.11
10^{-3}	59.04	58.96	59.11	59.04	58.96	59.11
10^{-4}	97.04	93.85	94.33	99.78	98.03	98.03
10^{-5}	100	99.01	99.01	99.94	98.28	97.53
10^{-6}	95.99	96.06	94.08	92.77	88.94	92.11

Tabla 15. Porcentajes de Accuracy para training, validation y test para Alexnet con el optimizador Adam.

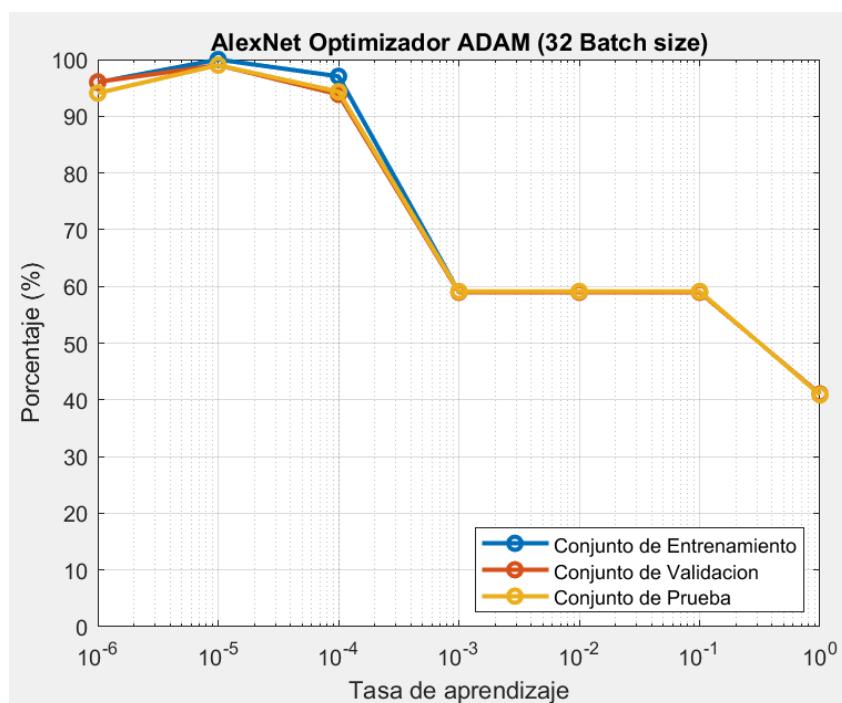


Figura 20. Gráfica porcentaje vs tasa de aprendizaje de la red Alexnet optimizador Adam (32 Batch size).

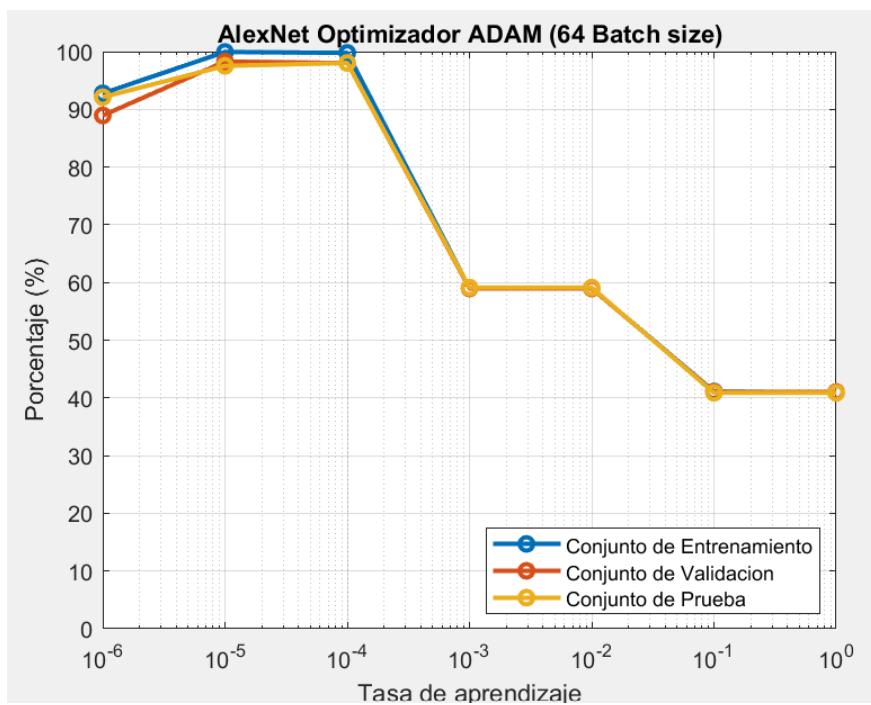


Figura 21. Gráfica porcentaje vs tasa de aprendizaje de la red Alexnet optimizador Adam (64 Batch size).

A continuación se tiene la tabla de los porcentajes de Accuracy para *training*, *validation* y *test* para Alexnet con el optimizador *sgdm*:

%Exactitud para Alexnet						
Learn Rate	Optimizador Sgdm					
	Batch Size					
	32			64		
	Entrenamiento(%)	Validación(%)	Prueba(%)	Entrenamiento(%)	Validación(%)	Prueba(%)
1	50.1	50.1	50.12	50.14	50.14	50
10^{-1}	49.8	51.21	51.21	50.45	50.3	50.3
10^{-2}	50.27	50.24	50.24	50	50	50
10^{-3}	98.73	94.34	93.10	95.99	93.85	91.62
10^{-4}	99.15	97.05	95.81	99.52	98.52	97.29
10^{-5}	96.83	94.34	96.55	94.51	94.10	94.33
10^{-6}	82.86	85.01	80.54	72.74	68.55	73.89

Tabla 16. Porcentajes de Accuracy para training, validation y test para Alexnet con el optimizador sgdm.

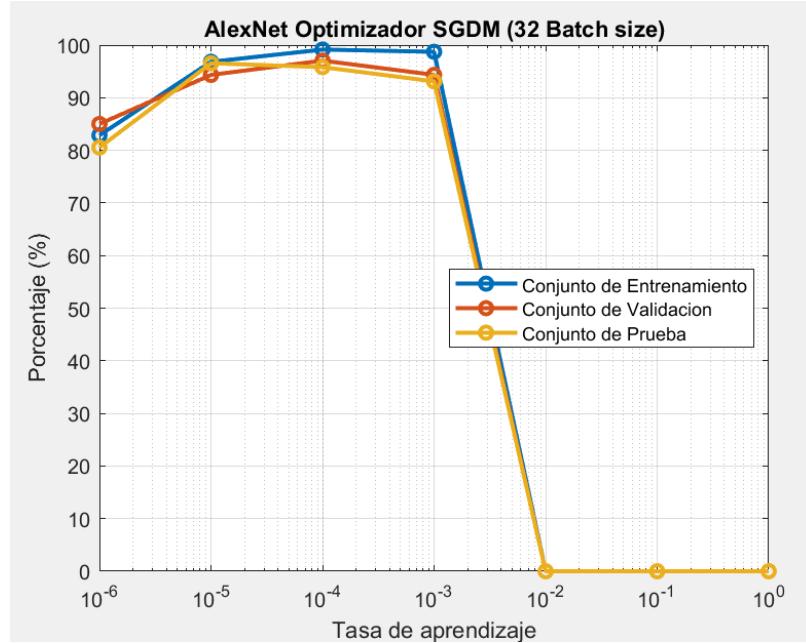


Figura 22. Gráfica porcentaje vs tasa de aprendizaje de la red Alexnet optimizador Sgdm (32 Batch size).

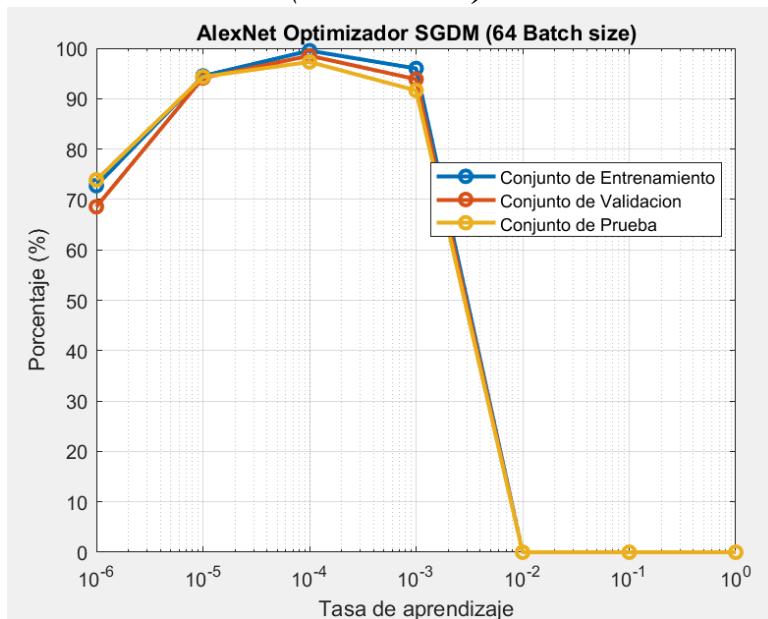


Figura 23. Gráfica porcentaje vs tasa de aprendizaje de la red Alexnet optimizador Sgdm (64 Batch size).

A continuación se tiene la tabla de los porcentajes de Accuracy para *training*, *validation* y *test* para Resnet 50 con el optimizador *rmsprop*:

%Exactitud para Resnet 50						
Learn Rate	Optimizador Rmsprop					
	Batch Size					
	32			64		
	Entrenamiento(%)	Validación(%)	Prueba(%)	Entrenamiento(%)	Validación(%)	Prueba(%)
1	49.04	58.34	58.11	57.84	58.77	58.93
10^{-1}	57.17	58.39	58.11	57.89	58.82	58.99
10^{-2}	57.28	58.51	58.11	57.92	58.77	58.93
10^{-3}	57.36	58.63	58.11	56.69	56.85	57.79
10^{-4}	96.47	94.35	93.82	98.29	93.15	94.68
10^{-5}	98.87	98.42	97.76	98.53	95.26	96.41
10^{-6}	95.48	93.87	94.81	90.12	88.89	89.34

Tabla 17. Porcentajes de Accuracy para training, validation y test para Resnet 50 con el optimizador rmsprop.

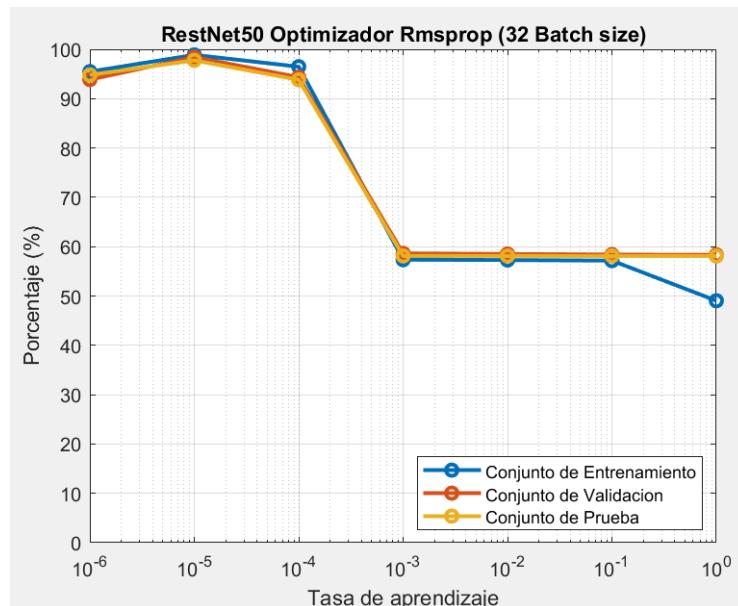


Figura 24. Gráfica porcentaje vs tasa de aprendizaje de la red Resnet 50 optimizador Rmsprop(32 Batch size).

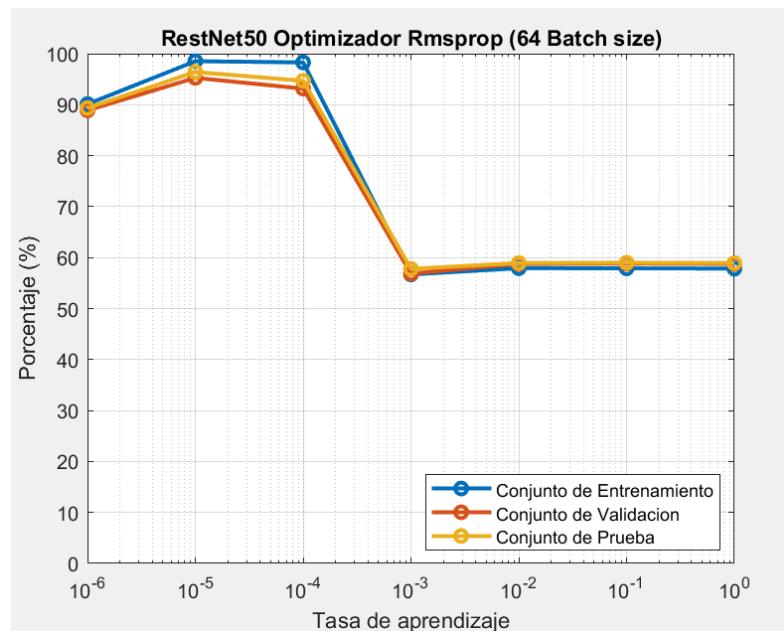


Figura 25. Gráfica porcentaje vs tasa de aprendizaje de la red Resnet 50 optimizador Rmsprop(64 Batch size).

A continuación se tiene la tabla de los porcentajes de *Accuracy* para *training*, *validation* y *test* para *Resnet 50* con el optimizador *adam*:

%Exactitud para Resnet 50						
Learn Rate	Optimizador Adam					
	Batch Size					
	32			64		
	Entrenamiento(%)	Validación(%)	Prueba(%)	Entrenamiento(%)	Validación(%)	Prueba(%)
1	39.92	40.94	39.75	39.02	39.99	39.75
10^{-1}	58.52	58.58	57.82	39.09	39.99	39.87
10^{-2}	58.56	58.63	57.96	57.03	57.95	58.03
10^{-3}	58.67	58.74	58.07	57.03	57.95	58.05
10^{-4}	95.78	92.77	92.25	97.77	96.02	97
10^{-5}	98.9	98.8	97.8	97.83	96.27	96.48
10^{-6}	94.56	95.89	92.89	90.76	86.93	91.07

Tabla 18. Porcentajes de Accuracy para training, validation y test para Resnet 50 con el optimizador Adam.

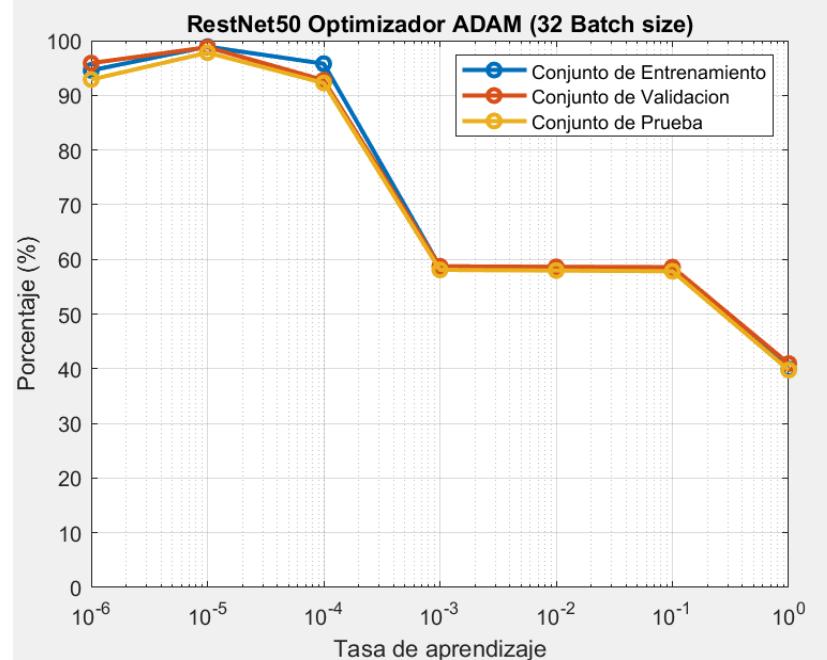


Figura 26. Gráfica porcentaje vs tasa de aprendizaje de la red Resnet 50 optimizador Adam(32 Batch size).

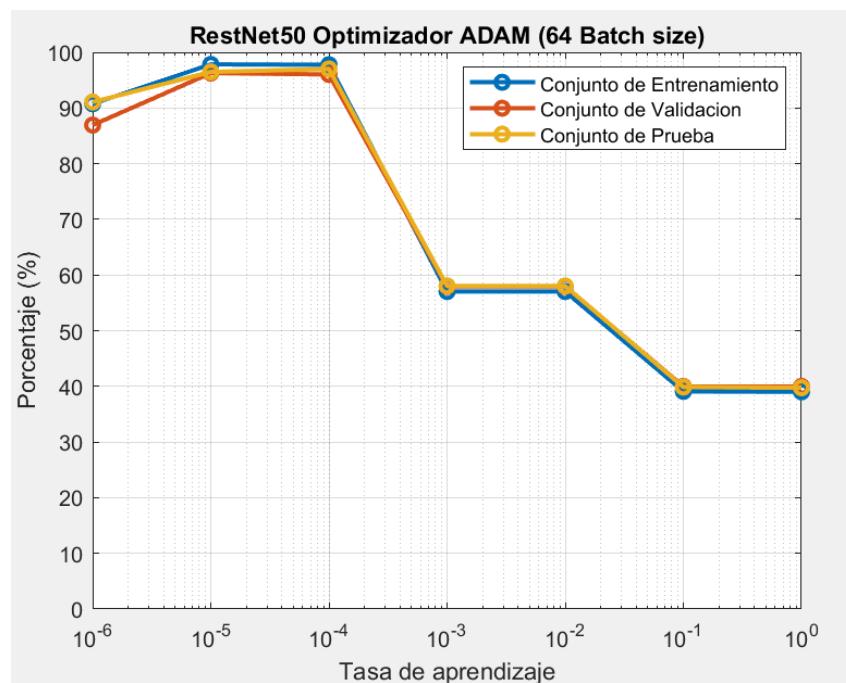


Figura 27. Gráfica porcentaje vs tasa de aprendizaje de la red Resnet 50 optimizador Adam(64 Batch size).

A continuación se tiene la tabla de los porcentajes de *Accuracy* para *training*, *validation* y *test* para *Resnet 50* con el optimizador *sgdm*:

%Exactitud para Resnet 50						
Learn Rate	Optimizador Sgdm					
	Batch Size					
	32			64		
	Entrenamiento(%)	Validación(%)	Prueba(%)	Entrenamiento(%)	Validación(%)	Prueba(%)
1	42.89	42.12	42.55	43.67	43.69	43.76
10^{-1}	58.18	59.01	58.24	57.78	58.14	57.9
10^{-2}	59.21	59.16	59.26	58.98	58.55	58.7
10^{-3}	96.69	93.11	92.56	94.99	92.56	90.57
10^{-4}	97.48	95.37	94.27	98.52	97.27	96.18
10^{-5}	95.17	93.11	95.03	93.51	93.05	93.24
10^{-6}	81.61	84.79	79.67	71.74	67.74	72.79

Tabla 19. Porcentajes de Accuracy para training, validation y test para Resnet 50 con el optimizador sgdm.

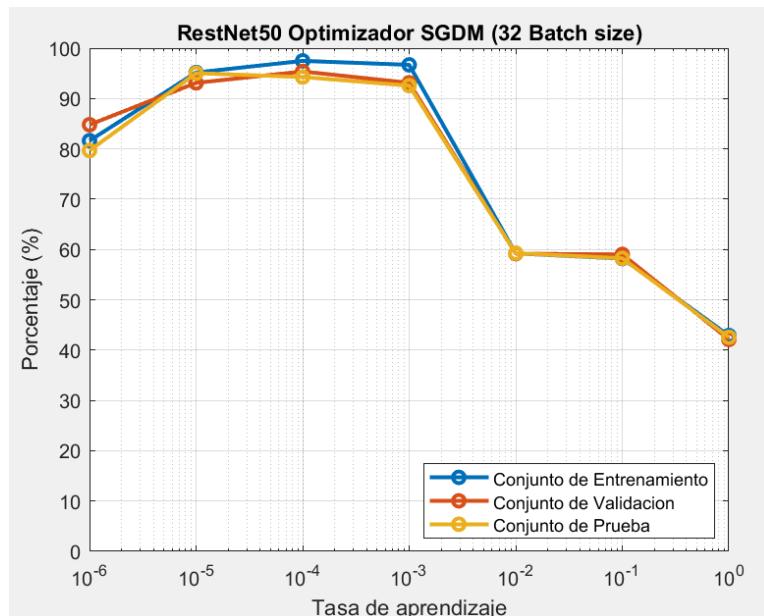


Figura 28. Gráfica porcentaje vs tasa de aprendizaje de la red Resnet 50 optimizador Sgdm(32 Batch size).

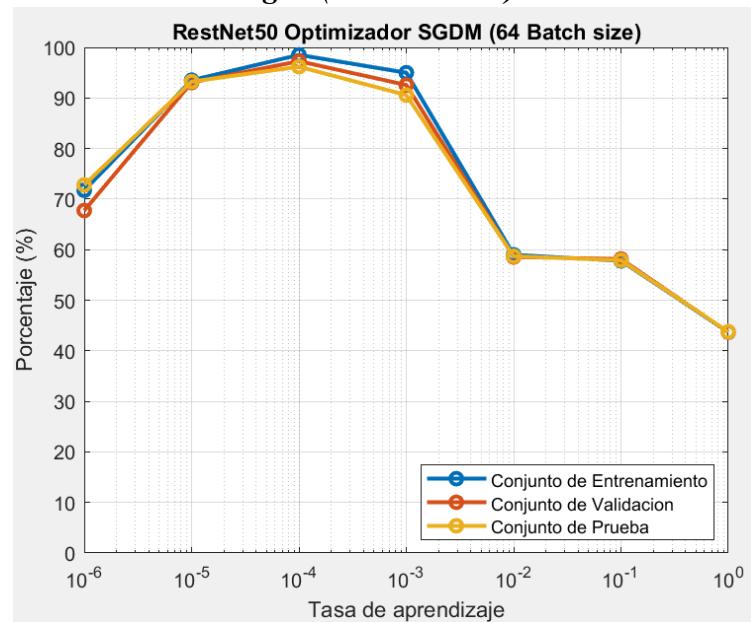


Figura 29. Gráfica porcentaje vs tasa de aprendizaje de la red Resnet 50 optimizador Sgdm(64 Batch size).

A continuación se tiene la tabla de los porcentajes de Accuracy para *training*, *validation* y *test* para vgg 16 con el optimizador *rmsprop*:

%Exactitud para Vgg16						
Learn Rate	Optimizador Rmsprop					
	Batch Size					
	32		64			
	Entrenamiento(%)	Validación(%)	Prueba(%)	Entrenamiento(%)	Validación(%)	Prueba(%)
1	50.05	50.21	50.1	51.22	50.31	50.35
10 ⁻¹	50.2	50.3	50.29	50.4	50.08	50.73
10 ⁻²	50.1	50.4	50.2	50.25	50.06	50.04
10 ⁻³	50.2	50.1	50	50.2	50.02	50.15
10 ⁻⁴	51	50.6	50.4	50.52	50.86	50.44
10 ⁻⁵	99.15	97.71	97.29	89.64	87.71	87.17
10 ⁻⁶	92.68	89.38	91.46	88.75	90.83	88.97

Tabla 20. Porcentajes de Accuracy para training, validation y test para Vgg 16 con el optimizador rmsprop.

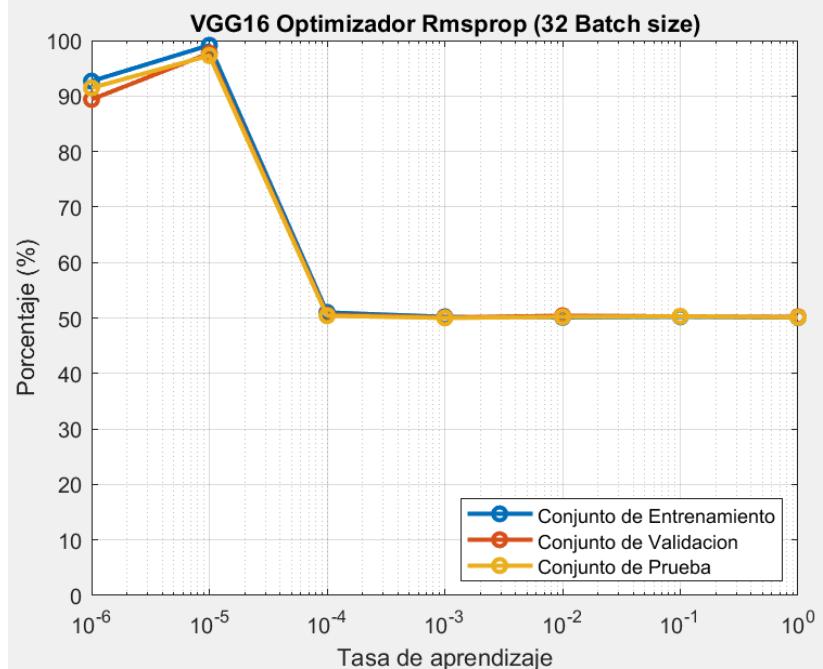


Figura 30. Gráfica porcentaje vs tasa de aprendizaje de la red Vgg 16 optimizador Rmsprop(32 Batch size).

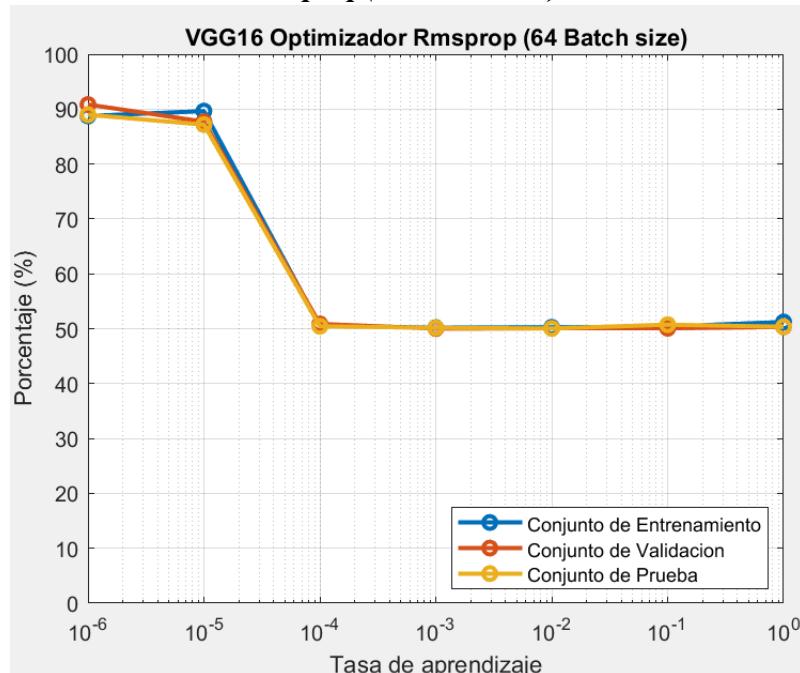


Figura 31. Gráfica porcentaje vs tasa de aprendizaje de la red Vgg 16 optimizador Rmsprop(64 Batch size).

A continuación se tiene la tabla de los porcentajes de *Accuracy* para *training*, *validation* y *test* para *vgg 16* con el optimizador *adam*:

%Exactitud para Vgg16						
Learn Rate	Optimizador Adam					
	Batch Size					
	32		64			
	Entrenamiento(%)	Validación(%)	Prueba(%)	Entrenamiento(%)	Validación(%)	Prueba(%)
1	50	50.05	50.1	50.1	50.15	50.14
10^{-1}	50.8	50.12	50.11	50.9	50.11	50.13
10^{-2}	50.07	52.1	52.04	50.3	52.52	50.44
10^{-3}	50	50	50	50.54	50.2	50.2
10^{-4}	51.3	50.04	50.1	50.11	51.33	51.33
10^{-5}	99.69	97.92	98.75	99.46	98.13	97.71
10^{-6}	95.63	92.08	93.96	93.79	91.67	93.96

Tabla 21. Porcentajes de *Accuracy* para *training*, *validation* y *test* para *Vgg 16* con el optimizador *Adam*.

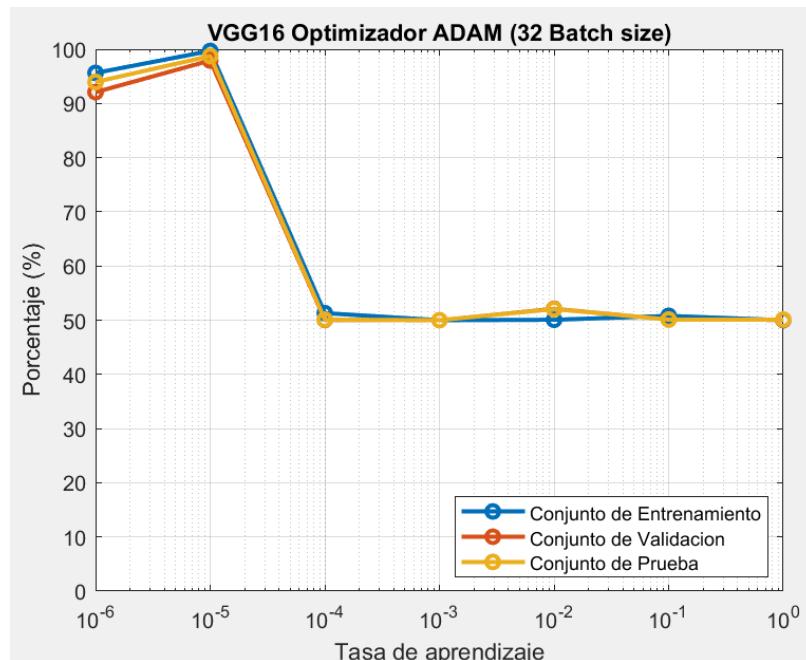


Figura 32. Gráfica porcentaje vs tasa de aprendizaje de la red Vgg 16 optimizador Adam(32 Batch size).

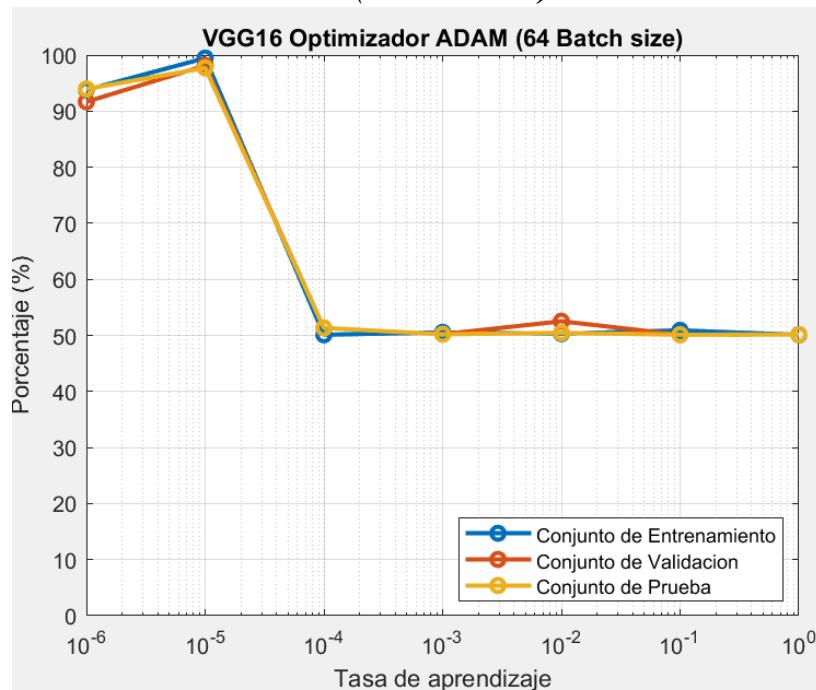


Figura 33. Gráfica porcentaje vs tasa de aprendizaje de la red Vgg 16 optimizador Adam(64 Batch size).

A continuación se tiene la tabla de los porcentajes de Accuracy para *training*, *validation* y *test* para vgg 16 con el optimizador *sgdm*:

%Exactitud para Vgg16						
Learn Rate	Optimizador Sgdm					
	Batch Size					
	32			64		
	Entrenamiento (%)	Validación (%)	Prueba (%)	Entrenamiento (%)	Validación (%)	Prueba (%)
1	51	50	50.3	50.01	50.74	50.78
10^{-1}	50.18	50.25	50.2	51.6	50	50.04
10^{-2}	50.05	50.2	50.8	50.71	50.65	50.33
10^{-3}	91.88	88.33	86.25	76.88	77.54	78.13
10^{-4}	78.39	78.75	78.33	71.29	73.33	73.33

10^{-5}	54.91	51.04	51.25	51.21	50.21	51.25
10^{-6}	47.95	48.12	48.05	50.13	50.42	50.83

Tabla 22. Porcentajes de Accuracy para training, validation y test para Vgg 16 con el optimizador sgdm.

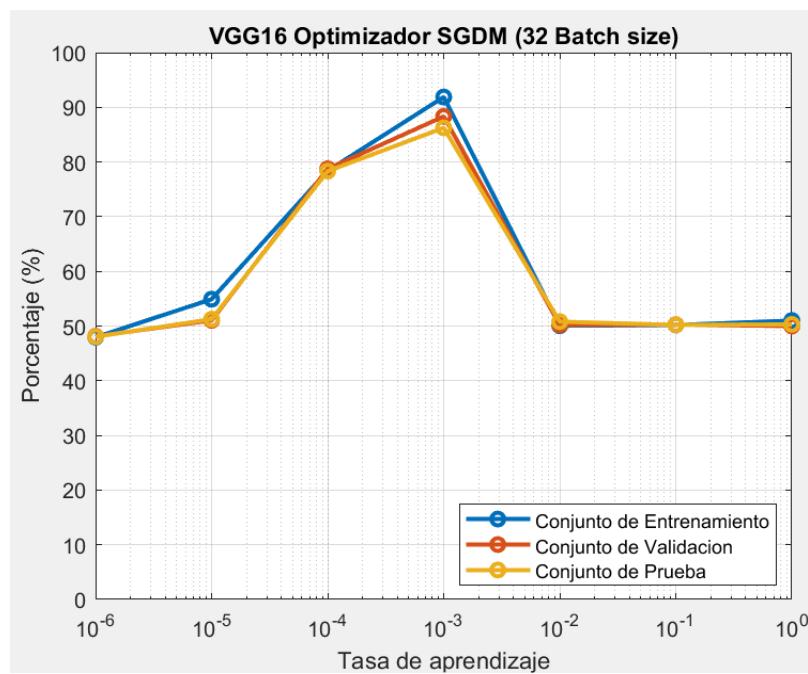


Figura 34. Gráfica porcentaje vs tasa de aprendizaje de la red Vgg 16 optimizador Sgdm(32 Batch size).

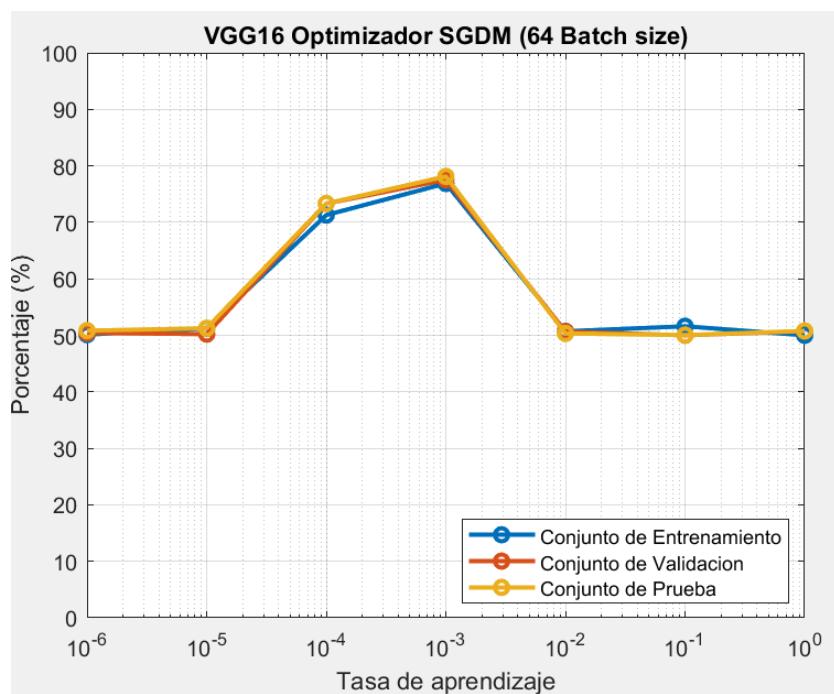


Figura 35. Gráfica porcentaje vs tasa de aprendizaje de la red Vgg 16 optimizador Sgdm(64 Batch size).

REDES PRE-ENTRENADAS	OPTIMIZADORES	LEARN RATE	BATCH SIZE 32		
			Entrenamiento (%)	Validación (%)	Prueba (%)
ALEXNET	RMSPROP	10^{-5}	99.89	98.77	98.76
	ADAM	10^{-5}	100	99.01	99.01
	SGDM	10^{-4}	99.15	97.05	95.81
RESNET 50	RMSPROP	10^{-5}	98.87	98.42	97.76
	ADAM	10^{-5}	98.90	98.80	97.80
	SGDM	10^{-4}	97.48	95.37	94.27
VGG 16	RMSPROP	10^{-5}	99.15	97.71	97.29
	ADAM	10^{-5}	99.69	97.92	98.75
	SGDM	10^{-3}	91.88	88.33	86.25

Tabla 23. Tabla comparativa de los valores más altos arrojados por alexnet, restnet50 y vgg16 (batch size 32).

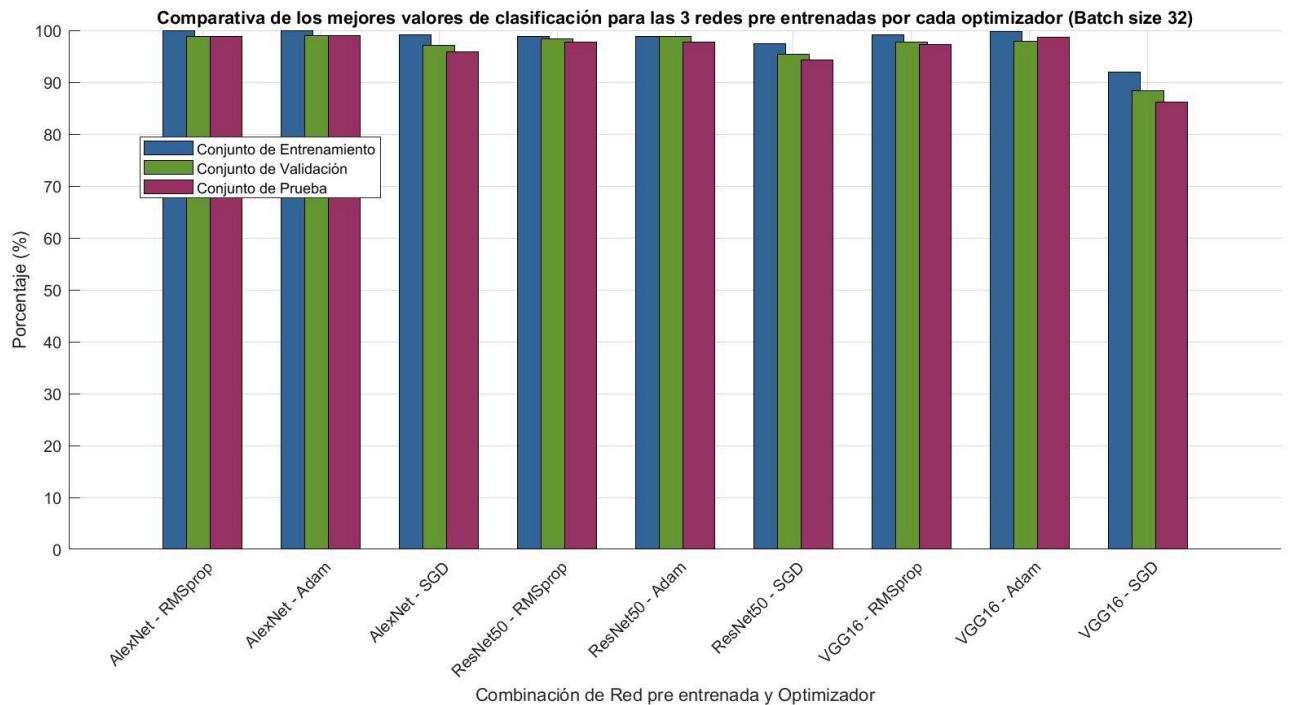


Figura 36. Gráfico comparativo de los mejores valores de clasificación para las 3 redes pre entrenadas por cada optimizador(32 Batch size).

Para la red pre entrenada AlexNet, el optimizador Adam muestra el mejor rendimiento en los conjuntos de entrenamiento, validación y prueba, con valores de 100%, 99.01% y 99.01% respectivamente. Para la red pre-entrenada ResNet50, el optimizador Adam también muestra el mejor rendimiento en los conjuntos de entrenamiento, validación y prueba, con valores de 98.90%, 98.80% y 97.80%. Para la red pre-entrenada VGG 16, el optimizador Adam también se destaca con valores de 99.69%, 97.92% y 98.75% en los conjuntos de entrenamiento, validación y prueba.

Aunque las combinaciones con otras redes pre entrenadas también muestran buen rendimiento, la combinación de Alexnet y Adam sigue siendo la más destacada.

REDES PRE-ENTRENADAS	OPTIMIZADORES	LEARN RATE	BATCH SIZE 64		
			Entrenamiento (%)	Validación (%)	Prueba (%)
ALEXNET	RMSPROP	10^{-5}	99.57	96.31	97.53
	ADAM	10^{-5}	99.94	98.28	97.53
	SGDM	10^{-4}	99.52	98.52	97.29
RESNET 50	RMSPROP	10^{-5}	98.53	95.26	96.41
	ADAM	10^{-5}	97.83	96.27	96.48
	SGDM	10^{-4}	98.52	97.27	96.18
VGG 16	RMSPROP	10^{-6}	88.75	90.83	88.97
	ADAM	10^{-5}	99.46	98.13	97.71
	SGDM	10^{-3}	76.88	77.54	78.13

Tabla 24. Tabla comparativa de los valores más altos arrojados por alexnet, restnet50 y vgg16 (batch size 64).

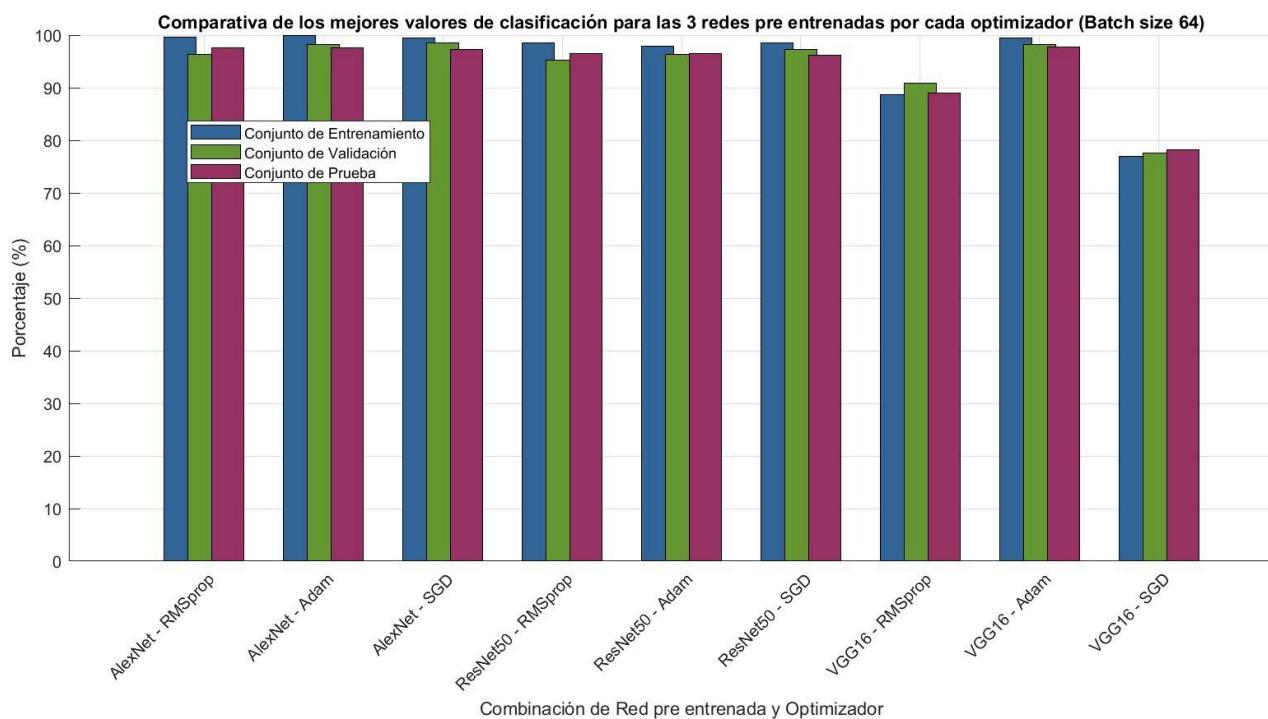


Figura 37. Gráfico comparativo de los mejores valores de clasificación para las 3 redes pre entrenadas por cada optimizador(64 Batch size).

Observamos que para la red pre entrenada AlexNet, el optimizador Adam muestra el rendimiento más alto en los conjuntos de entrenamiento, validación y prueba, con valores de 99.94%, 98.28% y 97.53% respectivamente. Por otro lado, para la red pre entrenada ResNet50, nuevamente el optimizador Adam muestra el mejor rendimiento en los conjuntos de entrenamiento, validación y prueba, con valores de 97.83%, 96.27% y 96.48%.

Y por último, para la red pre entrenada VGG 16, el optimizador Adam también se destaca con valores de 99.46%, 98.13% y 97.71% en los conjuntos de entrenamiento, validación y prueba.

Aunque las combinaciones con otras redes pre entrenadas también muestran buen rendimiento, la combinación de Alexnet y Adam destaca por su rendimiento sólido en los tres conjuntos de datos.

4.3.1 ANÁLISIS DE LOS CAMPEONES - TRANSFER LEARNING

Como se comentó anteriormente, el criterio para seleccionar estos campeones dentro de la investigación en la técnica de *transfer learning* es la exactitud (*Accuracy*). No obstante, para seleccionar el mejor entre los campeones se procede a sacar otras medidas de bondad que son oportunas para una selección precisa del modelo.

Estas medidas de bondad son: Exactitud (*Accuracy*), Sensibilidad (*Sensitivity or recall*), Precisión (*Precision*), Especificidad (*Specificity*) y la Puntuación F1 (*F1 Score*).

Ahora bien teniendo una matriz de confusión como:

		VALORES ACTUALES	
		SI	NO
VALORES PREVISTOS	SI	VERDADERO POSITIVO	FALSO POSITIVO
	NO	FALSO NEGATIVO	VERDADERO NEGATIVO

Figura 38. Ejemplo de Matriz de confusión.

Dónde: *True positive* es Verdaderos positivos, *False positive* es Falsos positivos,

False negative es Falsos negativos y *True positives* es Verdaderos negativos.

Las ecuaciones para calcularlas son las siguientes:

$$\text{Sensibilidad} = \text{Verdaderos Positivos}/(\text{Verdaderos Positivos} + \text{Falsos Negativos})$$

$$\text{Precisión} = \text{Verdaderos Positivos}/(\text{Verdaderos Positivos} + \text{Falsos Positivos})$$

$$\text{Especificidad} = \text{Verdaderos Negativos}/(\text{Verdaderos Negativos} + \text{Falsos Positivos})$$

$$\text{Puntuación F1 (F1 Score)} = 2 * (\text{Precisión} * \text{Sensibilidad})/(\text{Precisión} + \text{Sensibilidad})$$

La exactitud ya se había calculado por lo tanto solo se calculan las que se necesitan.

Ahora bien para poder calcular estas métricas indispensables de la inteligencia artificial se saca la matriz de confusión para cada conjunto de datos: Entrenamiento, Validación y Prueba. Se utiliza el comando `confusionmat` en Matlab para hallar sus matrices de confusión.

4.3.2 TABLAS RESUMEN - TRANSFER LEARNING

En este apartado, se presentan las medidas de bondad halladas usando la técnica de *transfer learning*, para la detección de cáncer de melanoma. La evaluación del rendimiento del modelo es fundamental para garantizar su confiabilidad en un contexto clínico. Para este propósito, se han utilizado varias *métricas* de evaluación aplicadas en la inteligencia artificial, usadas como criterio para seleccionar el mejor modelo.

Las métricas presentadas son:

- Exactitud (*Accuracy*): La proporción de predicciones correctas sobre el total de predicciones.
- Sensibilidad (*Sensitivity*): La capacidad del modelo para identificar correctamente los casos positivos (melanoma).
- Precisión (*Precision*): La proporción de verdaderos positivos entre todas las predicciones positivas.
- Especificidad (*Specificity*): La capacidad del modelo para identificar correctamente los casos negativos (no melanoma).
- Puntuación F1 (*F1 Score*): La media armónica entre la precisión y la sensibilidad, proporcionando un equilibrio entre ambas.

Las tablas a continuación detallan estos valores, proporcionando una visión completa del desempeño del modelo en la tarea de detección de melanoma. Estas métricas son esenciales para evaluar la efectividad del modelo y su potencial aplicación en la práctica médica. Para ello se presenta una tabla por cada medida de bondad para todos los mejores 18 modelos que se hallaron mediante el *transfer learning*.

Exactitud			
Red	Entrenamiento%	Validación%	Prueba%
Alexnet - RMSPROP - 32 BatchSize - LR 1e-05	99.89%	98.77%	98.76%
Alexnet - ADAM - 32 BatchSize - LR 1e-05	100%	99.01%	99.01%
Alexnet - SGDM - 32 BatchSize - LR 1e-04	99.15%	97.05%	95.81%
Resnet50 - RMSPROP - 32 BatchSize - LR 1e-05	98.17%	95.22%	95.22%
Resnet50 - ADAM - 32 BatchSize - LR 1e-05	98.90%	98.57%	97.47%
Resnet50 - SGDM - 32 BatchSize - LR 1e-04	97.67%	95.56%	94.46%
Vgg16 - RMSPROP - 32 BatchSize - LR 1e-05	99.15%	97.71%	97.29%
Vgg16 - ADAM - 32 BatchSize - LR 1e-05	99.42%	96.46%	97.92%
Vgg16 - SGDM - 32 BatchSize - LR 1e-03	94.33%	94.17%	93.54%
Alexnet - RMSPROP - 64 BatchSize - LR 1e-05	99.24%	99.17%	99.38%
Alexnet - ADAM - 64 BatchSize - LR 1e-05	99.94%	98.28%	97.53%
Alexnet - SGDM - 64 BatchSize - LR 1e-04	99.52%	98.52%	97.29%
Resnet50 - RMSPROP - 64 BatchSize - LR 1e-05	96.26%	92.99%	94.14%
Resnet50 - ADAM - 64 BatchSize - LR 1e-05	96.29%	94.73%	94.94%
Resnet50 - SGDM - 64 BatchSize - LR 1e-04	95.63%	94.38%	93.29%

Vgg16 - RMSPROP - 64 BatchSize - LR 1e-06	88.39%	87.29%	87.29%
Vgg16 - ADAM - 64 BatchSize - LR 1e-05	99.46%	98.13%	97.71%
Vgg16 - SGDM - 64 BatchSize - LR 1e-03	94.87%	92.29%	92.71%

Tabla 25. Tabla resumen de la Exactitud

Sensibilidad			
Red	Entrenamiento%	Validación%	Prueba%
Alexnet - RMSPROP - 32 BatchSize - LR 1e-05	99.20%	100%	99.17%
Alexnet - ADAM - 32 BatchSize - LR 1e-05	98.33%	98.13%	99.17%
Alexnet - SGDM - 32 BatchSize - LR 1e-04	78.13%	80.83%	79.17%
Resnet50 - RMSPROP - 32 BatchSize - LR 1e-05	98.21%	95.18%	95.18%
Resnet50 - ADAM - 32 BatchSize - LR 1e-05	98.93%	98.57%	97.50%
Resnet50 - SGDM - 32 BatchSize - LR 1e-04	97.68%	95.54%	94.46%
Vgg16 - RMSPROP - 32 BatchSize - LR 1e-05	99.11%	97.68%	97.32%
Vgg16 - ADAM - 32 BatchSize - LR 1e-05	99.82%	99.58%	99.17%
Vgg16 - SGDM - 32 BatchSize - LR 1e-03	93.30%	93.75%	93.33%
Alexnet - RMSPROP - 64 BatchSize - LR 1e-05	99.11%	98.33%	99.17%
Alexnet - ADAM - 64 BatchSize - LR 1e-05	99.29%	99.58%	98.93%
Alexnet - SGDM - 64 BatchSize - LR 1e-04	99.55%	98.48%	97.32%
Resnet50 - RMSPROP - 64 BatchSize - LR 1e-05	96.25%	92.95%	94.11%
Resnet50 - ADAM - 64 BatchSize - LR 1e-05	96.25%	94.73%	94.91%
Resnet50 - SGDM - 64 BatchSize - LR 1e-04	95.63%	94.38%	93.30%
Vgg16 - RMSPROP - 64 BatchSize - LR 1e-06	92.41%	91.41%	91.25%
Vgg16 - ADAM - 64 BatchSize - LR 1e-05	99.46%	99.58%	99.17%

Vgg16 - SGDM - 64 BatchSize - LR 1e-03	96.07%	93.75%	95.42%
---	--------	--------	--------

Tabla 26. Tabla resumen de la Sensibilidad

Precisión			
Red	Entrenamiento%	Validación%	Prueba%
Alexnet - RMSPROP - 32 BatchSize - LR 1e-05	99.55%	99.59%	100%
Alexnet - ADAM - 32 BatchSize - LR 1e-05	99.82%	99.58%	99.58%
Alexnet - SGDM - 32 BatchSize - LR 1e-04	80.79%	82.91%	80.17%
Resnet50 - RMSPROP - 32 BatchSize - LR 1e-05	98.13%	95.26%	95.26%
Resnet50 - ADAM - 32 BatchSize - LR 1e-05	98.57%	98.57%	97.41%
Resnet50 - SGDM - 32 BatchSize - LR 1e-04	97.68%	95.62%	94.46%
Vgg16 - RMSPROP - 32 BatchSize - LR 1e-05	99.20%	97.77%	97.23%
Vgg16 - ADAM - 32 BatchSize - LR 1e-05	99.03%	93.73%	96.75%
Vgg16 - SGDM - 32 BatchSize - LR 1e-03	95.26%	94.54%	93.72%
Alexnet - RMSPROP - 64 BatchSize - LR 1e-05	99.37%	100%	99.58%
Alexnet - ADAM - 64 BatchSize - LR 1e-05	98.93%	99.17%	98.74%
Alexnet - SGDM - 64 BatchSize - LR 1e-04	99.46%	98.57%	97.23%
Resnet50 - RMSPROP - 64 BatchSize - LR 1e-05	96.25%	93.03%	94.19%
Resnet50 - ADAM - 64 BatchSize - LR 1e-05	96.34%	94.73%	95.00%
Resnet50 - SGDM - 64 BatchSize - LR 1e-04	95.63%	94.38%	93.30%
Vgg16 - RMSPROP - 64 BatchSize - LR 1e-06	85.54%	84.56%	84.56%
Vgg16 - ADAM - 64 BatchSize - LR 1e-05	97.72%	97.95%	99.17%
Vgg16 - SGDM - 64 BatchSize - LR 1e-03	93.81%	91.09%	90.51%

Tabla 27. Tabla resumen de la Precisión

Especificidad			
Red	Entrenamiento%	Validación%	Prueba%
Alexnet - RMSPROP - 32 BatchSize - LR 1e-05	99.55%	99.58%	100%
Alexnet - ADAM - 32 BatchSize - LR 1e-05	99.82%	99.58%	99.58%
Alexnet - SGDM - 32 BatchSize - LR 1e-04	81.43%	83.33%	80.42%
Resnet50 - RMSPROP - 32 BatchSize - LR 1e-05	98.13%	95.27%	95.27%
Resnet50 - ADAM - 32 BatchSize - LR 1e-05	98.84%	98.57%	97.41%
Resnet50 - SGDM - 32 BatchSize - LR 1e-04	97.68%	95.63%	94.46%
Vgg16 - RMSPROP - 32 BatchSize - LR 1e-05	99.20%	97.77%	97.23%
Vgg16 - ADAM - 32 BatchSize - LR 1e-05	99.02%	93.33%	96.67%
Vgg16 - SGDM - 32 BatchSize - LR 1e-03	95.36%	94.58%	93.75%
Alexnet - RMSPROP - 64 BatchSize - LR 1e-05	99.38%	100%	99.58%
Alexnet - ADAM - 64 BatchSize - LR 1e-05	98.93%	99.17%	98.75%
Alexnet - SGDM - 64 BatchSize - LR 1e-04	99.46%	98.57%	97.23%
Resnet50 - RMSPROP - 64 BatchSize - LR 1e-05	96.25%	93.04%	94.20%
Resnet50 - ADAM - 64 BatchSize - LR 1e-05	96.34%	94.73%	95.00%
Resnet50 - SGDM - 64 BatchSize - LR 1e-04	95.63%	94.38%	93.30%
Vgg16 - RMSPROP - 64 BatchSize - LR 1e-06	84.38%	83.33%	83.33%
Vgg16 - ADAM - 64 BatchSize - LR 1e-05	97.68%	97.92%	99.17%
Vgg16 - SGDM - 64 BatchSize - LR 1e-03	93.66%	90.83%	90.00%

Tabla 28. Tabla resumen de la Especificidad

Puntuación F1			
Red	Entrenamiento%	Validación%	Prueba%
Alexnet - RMSPROP - 32 BatchSize - LR 1e-05	99.37%	99.79%	99.58%
Alexnet - ADAM - 32 BatchSize - LR 1e-05	98.96%	99.37%	98.85%
Alexnet - SGDM - 32 BatchSize - LR 1e-04	79.44%	81.86%	79.66%
Resnet50 - RMSPROP - 32 BatchSize - LR 1e-05	98.17%	95.22%	95.22%
Resnet50 - ADAM - 32 BatchSize - LR 1e-05	98.88%	98.57%	97.46%
Resnet50 - SGDM - 32 BatchSize - LR 1e-04	97.68%	95.58%	94.46%
Vgg16 - RMSPROP - 32 BatchSize - LR 1e-05	99.15%	97.72%	97.28%
Vgg16 - ADAM - 32 BatchSize - LR 1e-05	99.42%	96.57%	97.94%
Vgg16 - SGDM - 32 BatchSize - LR 1e-03	94.27%	94.14%	93.53%
Alexnet - RMSPROP - 64 BatchSize - LR 1e-05	99.24%	99.16%	99.37%
Alexnet - ADAM - 64 BatchSize - LR 1e-05	99.11%	99.38%	98.54%
Alexnet - SGDM - 64 BatchSize - LR 1e-04	99.51%	98.53%	97.28%
Resnet50 - RMSPROP - 64 BatchSize - LR 1e-05	96.25%	92.99%	94.15%
Resnet50 - ADAM - 64 BatchSize - LR 1e-05	96.29%	94.73%	94.95%
Resnet50 - SGDM - 64 BatchSize - LR 1e-04	95.63%	94.38%	93.30%
Vgg16 - RMSPROP - 64 BatchSize - LR 1e-06	88.84%	87.78%	87.78%
Vgg16 - ADAM - 64 BatchSize - LR 1e-05	98.58%	98.76%	99.17%
Vgg16 - SGDM - 64 BatchSize - LR 1e-03	94.93%	92.40%	92.90%

Tabla 29. Tabla resumen de la Puntuación F1 (F1 score)

Para ver su explicación y entender los criterios a tener en cuenta para seleccionar el mejor modelo de los 18 mejores modelos campeones de la investigación en *Transfer*

Learning, y la intercomparación con las demás técnicas, ir al apartado de 5.1 *Discusiones*.

4.4 CREACIÓN DEL MODELO DESDE CERO - FROM SCRATCH PYTHON

Ahora desde el punto de vista del *deep learning* lo más apropiado es hacer una intercomparación entre diferentes sus técnicas, lo cual es muy apropiado para abordar este problema desde una óptica profunda. En esta sección se procede a probar la técnica de creación de algoritmo desde cero (*From Scratch*) pero desde Python.

Python siendo un entorno de desarrollo libre, tiene demasiadas bibliotecas para trabajar aprendizaje profundo, siendo algunas de las principales: *Tensor Flow*, *Keras*, *PyTorch*, *MxNet*, *Caffe*, *Theano*, *Chainer*, *CNTK (Cognitive Toolkit)*. Dado a que los desarrolladores del presente proyecto buscan estrategias actuales para la creación de una estructura que clasifique bien la enfermedad del melanoma, se utiliza *Keras* (quien puede funcionar sobre *Tensor Flow*) ya que posee la capacidad para construir y entrenar modelos de redes neuronales muy eficientes.

No obstante, dentro de *Keras* hay un “Sintonizador de Parámetros” para redes neuronales convolucionales llamado *Keras Tuner* el cual puede construir mediante 4 optimizadores de hiper parámetros permitiendo definir la búsqueda de esos parámetros y luego busca optimizar las medidas de bondad dentro de sí mismo.

Estos optimizadores son: *Grid Search*, *Bayesian Search*, *Random Search* y *Hyperband Search*. A continuación se presentan las tablas resumen para estos 4 optimizadores:

Exactitud			
Red	Entrenamiento (%)	Validación (%)	Test (%)
Grid Search - Adam	96.47%	91.16%	91.12%
Grid Search - Rmsprop	93.13%	91.43%	91.43%
Bayesian Search - Adam	97.72%	93.19%	93.24%
Bayesian Search - Rmsprop	97.05%	92.50%	92.54%
Random Search - Adam	96.74%	92.14%	92.14%
Random Search - Rmsprop	96.83%	92.28%	92.28%
Hyperband Search - Adam	95.77%	92.23%	92.23%
Hyperband Search - Rmsprop	93.08%	91.61%	91.61%

Tabla 30. Exactitud para Optimizadores de Keras Tuner

Sensibilidad			
Red	Entrenamiento (%)	Validación (%)	Test (%)
Grid Search - Adam	96.43%	91.16%	91.16%
Grid Search - Rmsprop	93.13%	91.43%	91.43%
Bayesian Search - Adam	97.77%	93.21%	93.21%
Bayesian Search - Rmsprop	97.05%	92.50%	92.59%
Random Search - Adam	96.70%	92.14%	92.14%
Random Search - Rmsprop	96.68%	92.32%	92.32%
Hyperband Search - Adam	95.80%	92.23%	92.23%
Hyperband Search - Rmsprop	93.13%	91.61%	91.61%

Tabla 31. Sensibilidad para Optimizadores de Keras Tuner

Precisión			
Red	Entrenamiento (%)	Validación (%)	Test (%)
Grid Search - Adam	96.51%	91.16%	91.08%
Grid Search - Rmsprop	93.13%	91.43%	91.43%
Bayesian Search - Adam	97.68%	93.13%	93.30%
Bayesian Search - Rmsprop	97.05%	92.50%	92.51%
Random Search - Adam	96.78%	92.14%	92.14%
Random Search - Rmsprop	96.79%	92.24%	92.24%
Hyperband Search - Adam	95.72%	92.23%	92.23%
Hyperband Search - Rmsprop	93.04%	91.61%	91.61%

Tabla 32. Precisión para Optimizadores de Keras Tuner

Especificidad			
Red	Entrenamiento (%)	Validación (%)	Test (%)
Grid Search - Adam	96.52%	91.16%	91.07%
Grid Search - Rmsprop	93.13%	91.43%	91.43%
Bayesian Search - Adam	97.68%	93.13%	93.30%
Bayesian Search - Rmsprop	97.05%	92.50%	92.50%
Random Search - Adam	96.79%	92.14%	92.14%
Random Search - Rmsprop	96.79%	92.23%	92.23%
Hyperband Search - Adam	95.71%	92.23%	92.23%
Hyperband Search - Rmsprop	93.04%	91.61%	91.61%

Tabla 33. Especificidad para Optimizadores de Keras Tuner

Puntuación F1			
Red	Entrenamiento (%)	Validación (%)	Test (%)

Grid Search - Adam	96.47%	91.16%	91.12%
Grid Search - Rmsprop	93.13%	91.43%	91.43%
Bayesian Search - Adam	97.72%	93.17%	93.26%
Bayesian Search - Rmsprop	97.05%	92.50%	92.55%
Random Search - Adam	96.74%	92.14%	92.14%
Random Search - Rmsprop	96.83%	92.28%	92.28%
Hyperband Search - Adam	95.76%	92.23%	92.23%
Hyperband Search - Rmsprop	93.08%	91.61%	91.61%

Tabla 34. Puntuación F1 para Optimizadores de Keras Tuner

Estas son las medidas de bondad para los algoritmos dados por la biblioteca de *Keras Tuner* de Python con los optimizadores Adam y Rmsprop. Ahora bien, si tenemos en cuenta las medidas de bondad el valor más alto en la puntuación F1 es *Bayesian*, con un porcentaje de Validación del 93.17% con los siguientes hiper parámetros: Batch size de 32, *Learn rate* de 1e-06, y *Adam* como algoritmo optimizador en los *Layers*. Para entender por qué se selecciona la puntuación F1. (Ver sección 5.1 Discusiones)

4.5 INTERFAZ

En esta parte del proyecto se diseña una interfaz gráfica con el fin de realizar un ejecutable y que el sistema se pueda utilizar desde cualquier computador. Se realizó

la interfaz con dos colores, el naranja que representa entusiasmo, confianza, éxito, generosidad y además el color que resalta la Universidad UNAB, y el gris representa seguridad, modestia, confianza, inteligencia y conocimiento, a comparación de los otros colores que son poco amigables para lo que se busca en cuanto al objetivo del proyecto. La interfaz consta de dos ventanas, la primera es de inicio cuenta con su desarrolladores, nombre de la universidad, logotipo creado para el software, título y su botón de “inicio” que pasa a la ventana 2. Ventana de inicio ver en la siguiente *figura 39*.



Figura 39. Interfaz gráfica ventana 1(parte 1).

La segunda ventana tiene 2 botones, el primero sirve para importar la imagen, en este caso sería una imagen de un lunar o un melanoma, seguido hay otro botón, el cual es para clasificar la imagen y qué el sistema pueda determinar si es cáncer de

piel melanoma o no. Una vez se suba la imagen y se de click en el botón “clasificar” se prenderá alguno de los dos leds, ya sea si es melanoma o no melanoma. Y en la gráfica de la derecha, se mostrará la imagen cargada.

En la *Figura 40* se ve como es la segunda ventana sin realizar ningún paso.

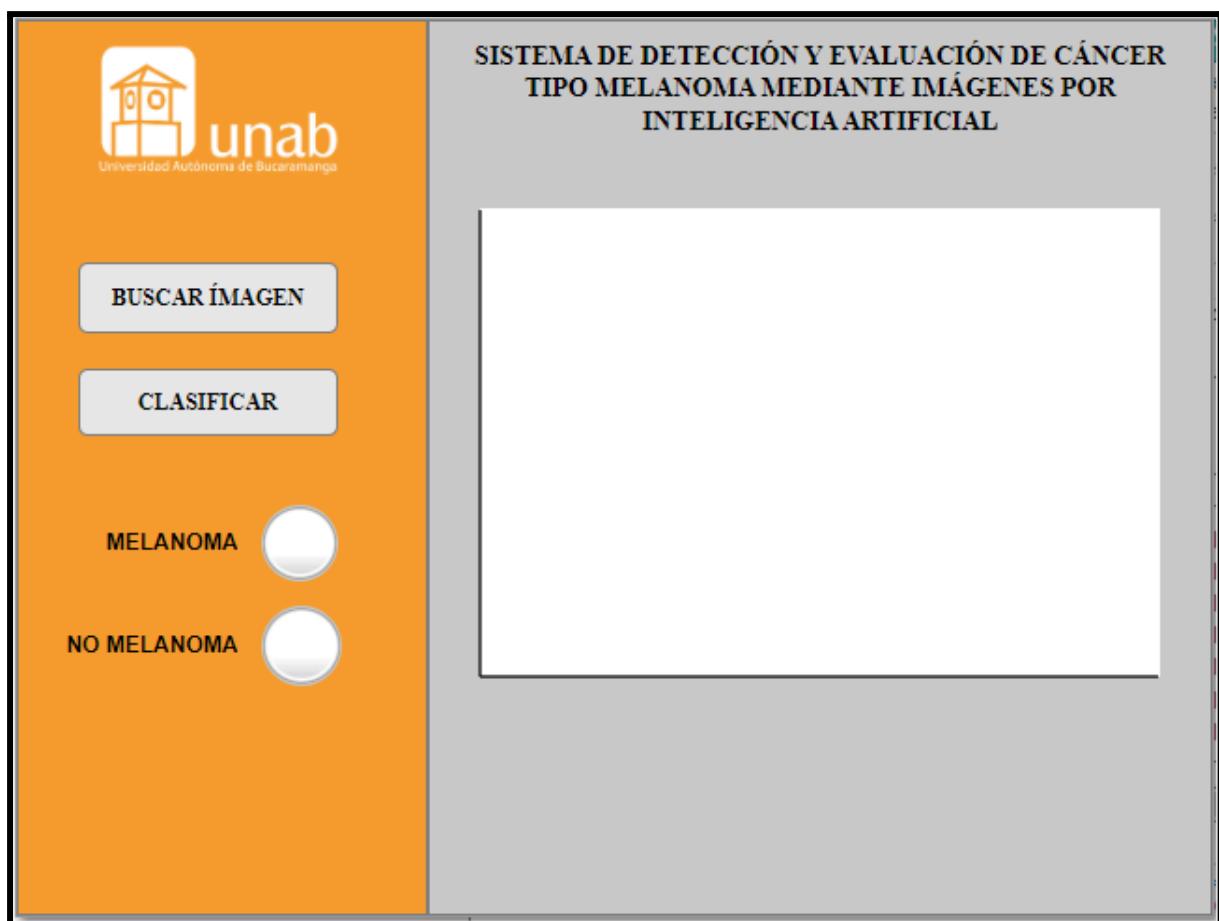


Figura 40. Interfaz gráfica ventana 2(parte 1).

En la *Figura 41* se aprecia en la parte derecha la imagen a clasificar. La imagen tiene unas dimensiones $n \times m$ y el modelo hace un redimensionamiento de la imagen automáticamente para facilitar su trabajo de clasificación.



Figura 41. Interfaz gráfica ventana 2(parte 2).

Cuando se da click en el botón de ‘Clasificar’, se enciende el Led Rojo, indicando que efectivamente la imagen es de melanoma. (Ver *Figura 42*)



Figura 42. Interfaz gráfica ventana 2 (parte 3).

Pero si la imagen no es melanoma el sistema enciende el led azul indicando que la fotografía no es melanoma (ver *figura 43*).



Figura 43. Interfaz gráfica ventana 2(parte 4).

4.5.1 MENÚ DE USUARIO

El diseño de la interfaz gráfica se realizó con el fin de que sea amigable con el usuario en cuanto a los colores y a su facilidad de uso. La interfaz gráfica se diseñó y programó en MATLAB para luego convertirla en un ejecutable con el fin de utilizar en cualquier dispositivo de cómputo. La siguiente *figura 44* muestra las partes de la interfaz.

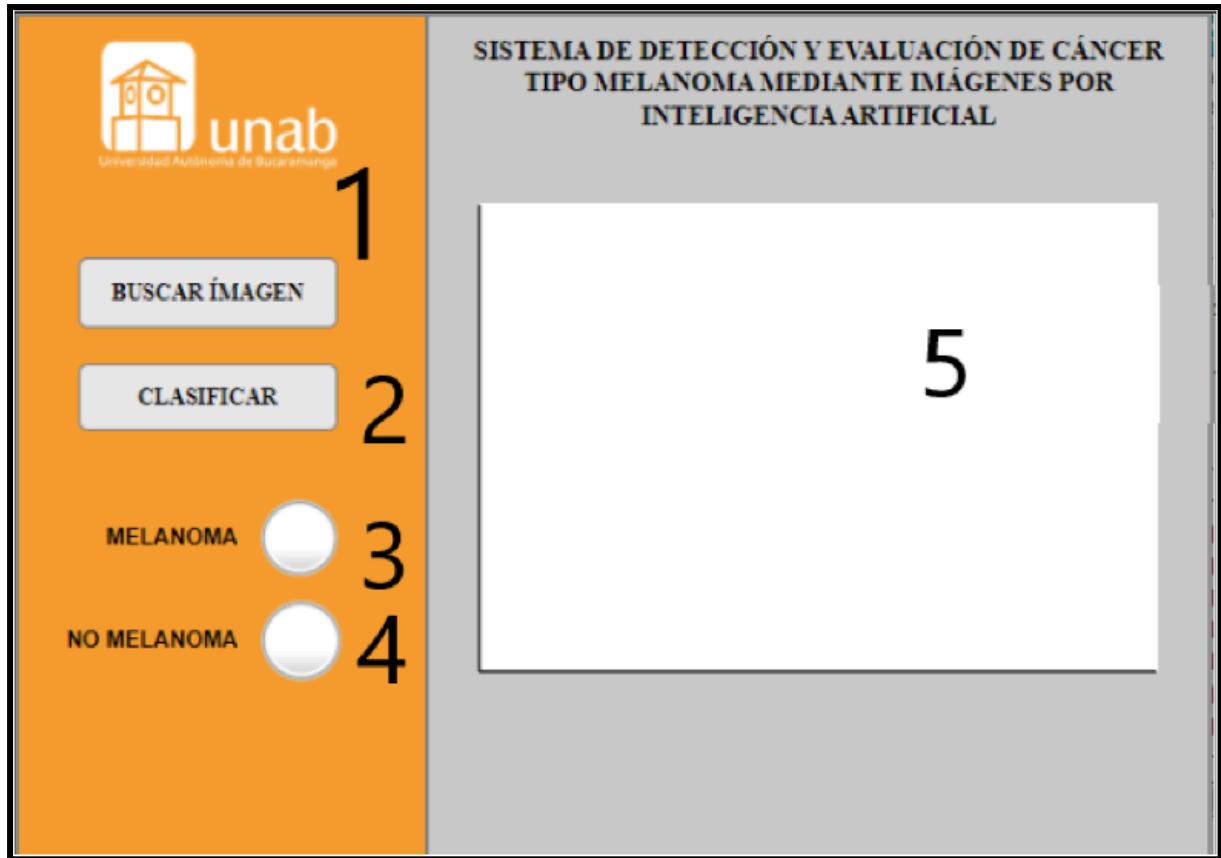


Figura 44. Partes de la interfaz gráfica .

4.5.2 EXPLICACIÓN DE LAS PARTES DE LA INTERFAZ

La interfaz de usuario posee 5 partes:

NÚMERO 1 (BOTÓN “BUSCAR IMAGEN”): Este botón se utiliza para importar la imagen desde la base de datos almacenada en el PC.

NÚMERO 2 (BOTÓN “CLASIFICAR”): Este botón se utiliza para una vez importada la imagen realice todo el proceso de clasificación y determinar si es o no melanoma.

NUMERO 3 LED (MELANOMA): Este led se enciende de color rojo para indicar que la imagen clasificada es melanoma.

NUMERO 4 LED (NO MELANOMA): Este led se enciende de color azul para indicar que la imagen clasificada no es melanoma.

NÚMERO 5 PANTALLA: En esta pantalla se podrá visualizar la imagen cargada con el botón “CARGAR IMAGEN”.

CAPÍTULO V

5.1 DISCUSIONES

Para seleccionar los 18 campeones en la técnica de transfer learning, se utilizó como criterio la medida de bondad de la exactitud (*accuracy*), con los más altos porcentajes del conjunto de validación. Ahora esos *campeones* se volvieron a correr para calcular su respectiva matriz de confusión y a partir de ella las demás medidas de bondad. Esas medidas de bondad son: Exactitud, sensibilidad (o *recall*), precisión, especificidad y Puntuación F1 (*F1 Score*).

Ahora bien, si se observan las tablas resumen de *transfer learning* encontramos porcentajes muy buenos, desde el 90% en adelante, pero ¿Esto qué significa?. Dado a que el problema es para el área de la salud, el *mejor modelo* se debe seleccionar por una medida de bondad que clasifique correctamente al enfermo que realmente tenga la enfermedad, con el fin de minimizar los falsos negativos (personas que si tienen la enfermedad pero que son clasificadas como no melanoma).

A continuación se analiza las métricas más recomendadas y su importancia en este contexto:

1. Sensibilidad:

Esta medida de bondad proporciona los casos positivos reales (verdaderos positivos) que el modelo identifica correctamente como positivos.

Una alta sensibilidad, en el contexto de la detección de melanoma, garantiza que la mayoría de las personas con la enfermedad sean realmente identificadas.

2. Precisión:

La precisión es la proporción de casos positivos predichos por el modelo que son realmente. Este valor asegura que las predicciones del modelo sean confiables y precisas, minimizando los falsos positivos (que son las personas que el modelo detectó como enfermas pero que realmente no lo están).

Diferencia entre Sensibilidad y Precisión:

La primera, analiza la enfermedad entre todos los enfermos. Pero la precisión, observa la relación entre los que sí están enfermos y los que fueron detectados como enfermos pero que no lo están. Es decir, la sensibilidad se concentra en capturar la mayoría de los casos positivos *reales*, mientras que la precisión se centra en las predicciones positivas *realizadas por el modelo*.

3. Puntuación F1:

Esta métrica combina las 2 anteriores medidas de bondad, proporcionando un equilibrio entre ellas. Esto es un punto clave porque se desea que el modelo sea preciso en sus predicciones positivas y sensible para capturar la mayoría de los casos positivos *reales*.

Aunque esta medida es muy útil en bases de datos desbalanceadas, y dado a que para la detección de esta enfermedad se utilizó una base de datos balanceada de 2000 positivos a melanoma y 2000 no enfermos, sigue siendo una métrica relevante y válida para este problema.

Es entonces a destacar que al seleccionar el *mejor modelo* para la detección de melanoma independiente de la técnica dentro del Aprendizaje profundo (*deep learning*), ya sea el utilizar modelos pre-entrenados (*transfer learning*), o creación de la estructura desde cero (*from scratch*) ya se la creada por los estudiantes o desde Python; la sensibilidad debe ser una métrica crítica a tener presente ya que garantiza la identificación adecuada de personas con la enfermedad. Esto es fundamental para evitar consecuencias graves debido a falsos negativos, donde los pacientes con melanoma no diagnosticados, podrían no recibir el oportuno tratamiento ante su inminente avance en metástasis.

Además, se debe considerar la precisión para asegurar que las predicciones positivas del modelo sean confiables y no resulten con un exceso de falsos positivos, siendo esto negativo para el sistema de salud en las intervenciones innecesarias y el daño psicológico en los pacientes.

En consecuencia, se *utiliza la medida Puntuación F1 como criterio final para elegir el mejor modelo*. Ya que esta tiene en cuenta un equilibrio entre la precisión y la sensibilidad siendo las métricas críticas para que el profesional de la salud tome decisiones acertadas en la detección del cáncer de piel de tipo melanoma.

En conocimiento de eso, en la tabla siguiente tabla se compara la Puntuación F1 para los 3 mejores modelos de las 3 técnicas utilizadas:

Puntuación F1 Comparación de los Mejores			
Técnica	Entrenamiento (%)	Validación (%)	Test (%)
From Scratch - Students Net	80.90%	80.07%	80.57%
Transfer Learning - Alexnet	99.37%	99.79%	99.58%
From Scratch Python - Bayesian	97.72%	93.17%	93.26%

Tabla 35. Comparación de los mejores modelos.

Explicación y Análisis de los Mejores Modelos

1. From Scratch - Students Net: Esta red fue creada desde cero por los estudiantes en Matlab, parametrizada con los algoritmos optimizadores Adam, Rmsprop y Sgdm (ver sección 4.2). Sus parámetros incluyen la estructura mostrada en la Figura 17, una tasa de aprendizaje de 2.7e-05 y Adam como optimizador.

2. Transfer Learning - Alexnet: Este es el mejor modelo entre los 18 campeones, utilizando redes pre entrenadas como Alexnet, Resnet50 y Vgg16. Estas grandes redes fueron sintonizadas con los mismos algoritmos optimizadores (Adam, Rmsprop y Sgdm), además de ajustar la tasa de aprendizaje y el tamaño del batch.

3. From Scratch Python: Esta red fue optimizada usando la biblioteca Keras Tuner para los optimizadores *Adam* y *Rmsprop*, buscando los mejores hiper parámetros con sus cuatro algoritmos de sintonización de hiper parámetros (*Grid Search*,

HyperBand Search, Bayesian Search y Random Search). El algoritmo ganador por esta técnica fue *Bayesian Search* con *Adam*, con los siguientes hiper parámetros: batch size de 32, tasa de aprendizaje de 1e-06 y Adam como optimizador.

De los tres modelos, el mejor es la red pre entrenada *Alexnet*, que obtuvo un porcentaje de *validación* para la *Puntuación F1* del 99.79%. Los hiper parámetros utilizados para este modelo fueron:

- *Batch size*: 32
- Tasa de aprendizaje: 1e-05
- Optimizador: *Rmsprop*

Sin embargo se le presenta al personal médico el porcentaje del conjunto de Test para la *puntuación F1* con un 99.58% por que es el conjunto que da confiabilidad de que el modelo generaliza bien nuevos datos que no había utilizado en su entrenamiento y validación.

5.2 CONCLUSIONES Y RECOMENDACIONES

CONCLUSIONES

Se ha observado que para el entrenamiento del sistema se debe tener en cuenta los atributos presentes en la imagen, es por esta razón que se vio la necesidad de realizar un par de ajustes como igualar las imágenes. Este preprocessamiento consistió en redimensionar el tamaño de todas las imágenes con el fin de evitar que los diferentes tamaños de las imágenes se pudieran convertir en un impedimento para el entrenamiento.

El porcentaje de la *Puntuación F1* obtenido de la creación del modelo desde cero es del 80.07%. Este es un porcentaje que al personal de salud le podría generar desconfianza en el modelo. Sin embargo, para el *transfer learning* se encontró un *Puntuación F1* del 99.79% siendo un valor excelente para este proyecto.

Se determinó que la medida de bondad más calificada para seleccionar el mejor modelo es la puntuación F1. Porque este considera otras dos medidas de bondad al mismo tiempo, siendo la sensibilidad y la precisión. La primera, se enfoca en garantizar la identificación adecuada de personas con la enfermedad y la precisión para asegurar que las predicciones positivas del modelo sean confiables y no resulten con un exceso de falsos positivos (personas sanas detectadas como positivas).

Se realizó la interfaz de usuario, teniendo en cuenta que sea amigable con el usuario y su uso sea fácil e intuitivo, sus partes son 5, 2 botones, 2 leds y una

pantalla, siendo suficiente para obtener la clasificación del melanoma. Se validó el funcionamiento de la misma a través de sus pruebas obteniendo resultados óptimos tomando como referencia el objetivo general del proyecto.

La implementación de una interfaz de usuario para la clasificación de imágenes destinadas a determinar la presencia de cáncer de tipo melanoma demuestra un avance en la accesibilidad y usabilidad del sistema.

Teniendo en cuenta la investigación realizada, el modelo elegido y sus pruebas de funcionamiento, significa que la metodología del *transfer learning* es una estrategia importante y rápida que los ingenieros biomédicos pueden abordar para solucionar problemas en el área de la salud.

RECOMENDACIONES

El modelo de detección puede entrenarse para llegar a clasificar con qué grado de evolución o metástasis está enfermedad

Establecer colaboraciones con dermatólogos y profesionales médicos especializados en cáncer de piel para obtener retroalimentación y validación clínica del sistema. Su aporte puede mejorar la relevancia clínica del modelo.

Analizar y abordar las implicaciones éticas y legales de implementar este tipo de sistemas. Garantizar la privacidad de los datos, el consentimiento informado y la conformidad con regulaciones médicas y de protección de la información es esencial.

El proyecto podría ayudar a las personas que están en zonas no urbanas y con mucha exposición al sol, donde puedan autoevaluar las manchas extrañas y nuevas en su cuerpo, por medio de un aplicativo móvil.

El modelo puede utilizarse en *transfer learning* para aprender otros tipo de cáncer de piel que no sean de tipo melanoma.

Se podría especular en la creación de un modelo de regresión que a partir de una foto, se haga predicción si en el futuro se convertirá en cáncer de piel, una mancha inusual.

5.2 REFERENCIAS

Datos | Cáncer de Piel - Liga Colombiana contra el Cáncer. (s. f.). *Liga Colombiana contra el Cáncer.* <https://www.ligacancercolombia.org/educacion/datos-cancer-de-piel/#:~:text=Se%20estima%20sobre%20este%20mismo,4%20por%20100.000%20en%20hombres>

Estadísticas importantes sobre el cáncer de piel tipo melanoma. (s. f.). American Cancer Society | Information and Resources about for Cancer: Breast, Colon, Lung, Prostate, Skin. <https://www.cancer.org/es/cancer/cancer-de-piel-tipo-melanoma/acerca/estadisticas-clave.html>

Día mundial del melanoma 2022 | Cuenta de Alto Costo. (s. f.). *Cuenta de Alto Costo.* <https://cuentadealtocosto.org/site/cancer/dia-mundial-del-melanoma-2022/>

Cáncer. (s. f.). Recuperado 21 de septiembre de 2022, de <https://medlineplus.gov/spanish/ency/article/001289.htm#:~:text=El%20c%C3%A1ncer%20se%20origina%20de,c%C3%A9lulas%20crezcan%20%20fueran%20de%20control>

Etapas del cáncer de piel tipo melanoma. (s. f.). Recuperado 21 de septiembre de 2022, de <https://www.cancer.org/es/cancer/cancer-de-piel-tipo-melanoma/deteccion-diagnostico-clasificacion-por-etapas/clasificacion-por-etapas-el-cancer-de-piel-tipo-melanoma.html>

Valencia, D. (2022, 6 septiembre). En 30% ha aumentado la mortalidad por melanoma en Colombia. Caracol Radio. Recuperado 21 de septiembre de 2022, de https://caracol.com.co/radio/2022/08/09/salud/1660067928_028219.html

Yifan Yang. 2021. Data Augmentation to Improve the diagnosis of Melanoma using Convolutional Neural Networks. In Proceedings of the 2021 International Conference on Bioinformatics and Intelligent Computing (BIC 2021). Association for Computing Machinery, New York, NY, USA, 151–158. <https://doi.org/10.1145/3448748.3448773>

(S/f). Researchgate.net. Recuperado el 21 de septiembre de 2022, de https://www.researchgate.net/publication/355495450_Evaluation_of_Various_Open-Set_Medical_Imaging_Tasks_with_Deep_Neural_Networks

Gu, Y., Ge, Z., Bonnington, C. P., & Zhou, J. (2020). Progressive Transfer Learning and Adversarial Domain Adaptation for Cross-Domain Skin Disease Classification. *IEEE journal of biomedical and health informatics*, 24(5), 1379–1393. <https://doi.org/10.1109/JBHI.2019.2942429>

Machine Learning based System for Prediction of Breast Cancer Severity. (2019, 1 octubre). *IEEE Conference Publication | IEEE Xplore.* Recuperado 21 de septiembre de 2022, de <https://ieeexplore.ieee.org/document/8942575/>

Melanoma Skin Cancer Detection Using Deep Learning and Advanced Regularizer. (2020, 17 octubre). *IEEE Conference Publication | IEEE Xplore.* Recuperado 21 de septiembre de 2022, de <https://ieeexplore.ieee.org/document/9263118>

Estadísticas importantes sobre el cáncer de piel tipo melanoma. (2022). Retrieved October 9, 2022, from Cancer.org website: <https://www.cancer.org/es/cancer/cancer-de-piel-tipo-melanoma/acerca/estadisticas-clave.html>

Jeffrey Theodore Heaton. (2017, October 29). *Ian Goodfellow, Yoshua Bengio, and Aaron Courville: Deep learning: The MIT Press, 2016, 800 pp, ISBN:...* Retrieved October 10, 2022, from ResearchGate website: https://www.researchgate.net/publication/320703571_Ian_Goodfellow_Yoshua_Bengio_and_Aaron_Courville_Deep_learning_TheMIT_Press_2016_800_pp_ISBN_0262035618

Lunares. (2021). Retrieved October 9, 2022, from Medlineplus.gov website: <https://medlineplus.gov/spanish/moles.html>

Jones, O. T., Ranmuthu, C. K. I., Hall, P. N., Funston, G., & Walter, F. M. (2019). *Recognising Skin Cancer in Primary Care.* *Advances in Therapy*, 37(1), 603–616. <https://doi.org/10.1007/s12325-019-01130-1>

Avilés-Izquierdo, J. A., Ciudad-Blanco, C., Sánchez-Herrero, A., Mateos-Mayo, A., Nieto-Benito, L. M., & Rodríguez-Lomba, E. (2019). *Dermoscopy of cutaneous melanoma metastases: A color-based pattern classification.* *The Journal of Dermatology*, 46(7), 564–569. <https://doi.org/10.1111/1346-8138.14926>

A Guide to Convolutional Neural Networks for Computer Vision | Synthesis Lectures on Computer Vision. (2018). Retrieved October 10, 2022, from Morganclaypool.com website: <https://www.morganclaypool.com/doi/10.2200/S00822ED1V01Y201712COV015>

Ley 1581 de 2012 - Gestor Normativo. (2022, 2 marzo). *FunciÃ3n PÃoblica.* <https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=49981>

Decreto Número 1360 de 1989 (Junio 23) El Presidente de ... - UNAL.EDU.CO (no date). Available at: https://propiedadintelectual.unal.edu.co/fileadmin/recursos/innovacion/docs/normatividad_pi/decreto1360_1989.pdf (Accessed: October 26, 2022).

Leyes desde 1992 - Vigencia expresa y control de constitucionalidad [LEY_0044_1993]. (s. f.). *SECRETARÍA GENERAL DEL SENADO.* http://www.secretariasenado.gov.co/senado/basedoc/ley_0044_1993.html

De la Ley 1915 de 2018 al Tratado de Libre Comercio entre Colombia y Estados Unidos: algunas implicaciones para la protección del autor y su obra en el entorno

digital. (s. f.). Revistas Universidad Externado de Colombia.
<https://revistas.uexternado.edu.co/index.php/propin/article/view/6072>

Ley 23 de 1982 - Gestor Normativo. (s. f.). Inicio - Función Pública.
<https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=3431#:~:text=Esta%20Ley%20protege%20exclusivamente%20la,obras%20literarias,%20científicas%20y%20artísticas.>

Bagazgoitia, D. L. (2019, 30 abril). ¿Los lunares son siempre marrones? Doctora Lorea Bagazgoitia.
<https://dermatologia-bagazgoitia.com/2019/05/los-lunares-son-siempre-marrones-4683>

Troya-Martín, D. M. (2008, 1 febrero). Estudio dermoscópico del melanoma maligno cutáneo: análisis descriptivo de 45 casos | Actas Dermo-Sifiliográficas.
<https://www.actasdermo.org/es-estudio-dermoscopico-del-melanoma-maligno-articulo-S0001731008746143>

Cáncer de piel - Melanoma síntomas. (s. f.). Recuperado 26 de octubre de 2022, de
<https://www.contraelcancer.es/es/todo-sobre-cancer/tipos-cancer/cancer-piel/melanoma/sintomas>

Bibliografía Melanoma. (2023, julio 22). Mayoclinic.org.
<https://www.mayoclinic.org/es/diseases-conditions/melanoma/symptoms-causes/syc-20374884>